ML_Models_Training,_Optimization_and_Deployment

July 23, 2025

0.1 Abstract

Proiectul a vizat clasificarea calității vinului utilizând algoritmii **Ridge Classifier, XGBoost**, dar și o rețea neuronală **MLP (Multilayer Perceptron)** asupra caracteristicilor fizico-chimici. Setul de date a inclus 4.899 de probe de vin alb, cu variabile precum aciditate fixă și volatilă, acid citric, zahăr rezidual, cloruri, dioxid de sulf, densitate, pH, sulfați și alcool. Calitatea a fost etichetată în trei categorii: **low (3–4), medium (5–6)** și **high (7–8-9)**. Datele au fost împărțite 70% pentru antrenare, 10% evaluare și 20% pentru testare.

1 RidgeClassifier

Ridge Classifier a fost ales pentru capacitatea de regularizare L2, penalizând coeficienții mari și reducând varianța estimărilor, ceea ce stabilizează modelul, prevenind overfitt-ul, dar și gestionarea a corelațiilor dintre variabile. De asemenea, calitatea vinului a fost etichetată ca low, medium și high, iar RidgeClassifier funcționează bine pentru probleme de clasificare mult-clasă și poate fi eficient ca o extensie a regresiei liniar-penalizate.

Modelul final a demonstrat că proprietătile fizico-chimice pot prezice eficient nivelul calitătii vinului.

```
White wine shape: (4898, 12)
fixed acidity volatile acidity citric acid residual sugar chlorides

0 7.0 0.27 0.36 20.7 0.045
```

```
6.3
                              0.30
                                           0.34
                                                            1.6
                                                                     0.049
1
2
             8.1
                              0.28
                                           0.40
                                                            6.9
                                                                     0.050
3
             7.2
                              0.23
                                           0.32
                                                            8.5
                                                                     0.058
4
             7.2
                              0.23
                                           0.32
                                                            8.5
                                                                     0.058
   free sulfur dioxide total sulfur dioxide density
                                                         pH sulphates \
                  45.0
                                               1.0010 3.00
                                                                  0.45
0
                                       170.0
                  14.0
                                               0.9940 3.30
                                                                  0.49
                                       132.0
1
2
                  30.0
                                        97.0 0.9951 3.26
                                                                  0.44
3
                  47.0
                                       186.0 0.9956 3.19
                                                                  0.40
4
                  47.0
                                       186.0 0.9956 3.19
                                                                  0.40
   alcohol quality
       8.8
0
       9.5
                  6
1
                  6
      10.1
3
       9.9
                  6
       9.9
                  6
print("Valori lipsă pe coloană:\n", white_df.isnull().sum())
print("Număr rânduri duplicate:", white_df.duplicated().sum())
Valori lipsă pe coloană:
fixed acidity
                         0
volatile acidity
citric acid
                        0
residual sugar
                        0
chlorides
                        0
free sulfur dioxide
                        0
total sulfur dioxide
density
рΗ
                        0
sulphates
                        0
alcohol
                        0
                        0
quality
dtype: int64
Număr rânduri duplicate: 937
white_df = white_df.drop_duplicates()
# Split în train/test (80/20)
train_white, test_white = train_test_split(
    white_df,
    test_size=0.2,
    random_state=42,
    stratify=white_df["quality"]
)
```

```
# Verificăm dimensiuni
print("Train shape:", train_white.shape)
print("Test shape:", test_white.shape)
# Distribuția etichetelor
print("Train distribution:\n", train_white["quality"].value_counts().
  ⇔sort_index())
print("Test distribution:\n", test_white["quality"].value_counts().sort_index())
Train shape: (3168, 12)
Test shape: (793, 12)
Train distribution:
quality
3
      16
4
      122
5
     940
6
    1430
7
     551
8
      105
9
        4
Name: count, dtype: int64
Test distribution:
quality
      4
4
      31
5
     235
6
     358
7
    138
      26
8
9
       1
Name: count, dtype: int64
def map_quality(q):
    if q in [3, 4]:
        return "low"
    elif q in [5, 6]:
        return "medium"
    else:
        return "high"
train_white["quality_group"] = train_white["quality"].apply(map_quality)
test_white["quality_group"] = test_white["quality"].apply(map_quality)
print("Distribuție train:")
print(train_white["quality_group"].value_counts())
print("\nDistribuţie test:")
print(test_white["quality_group"].value_counts())
```

Distribuție train:

```
quality_group
medium
          2370
           660
high
low
           138
Name: count, dtype: int64
Distribuție test:
quality_group
medium
          593
high
          165
low
           35
Name: count, dtype: int64
X_train = train_white.drop(["quality", "quality_group"], axis=1)
y_train = train_white["quality_group"]
X_test = test_white.drop(["quality", "quality_group"], axis=1)
y_test = test_white["quality_group"]
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

2 Baseline model

Acuratețea modelului RidgeClassifier pe grupuri: 77.43%

	precision	recall	f1-score	support
high	0.71	0.22	0.33	165
low	0.00	0.00	0.00	35
medium	0.78	0.97	0.87	593
accuracy			0.77	793
macro avg	0.49	0.40	0.40	793
weighted avg	0.73	0.77	0.72	793

/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))

Acuratețea modelului RidgeClassifier pe grupuri: 77.43%

Classification Report: precision recall f1-score support

high	0.71	0.22	0.33	165
low	0.00	0.00	0.00	35
medium	0.78	0.97	0.87	593
accuracy			0.77	793
macro avg	0.49	0.40	0.40	793
weighted avg	0.73	0.77	0.72	793

Modelul tinde să ghicească clasa majoritară corect, dar ignoră complet celelalte două clase.

Clasa medium: Recall: 0.97: aproape toate instanțele de medium au fost corect prezise. Precision: 0.78: dintre predicțiile medium, majoritatea este corectă. Modelul este extrem de înclinat spre clasa medium.

Clasa high: Recall: 0.22: doar 22% din vinurile high au fost corect identificate. Precision: 0.71: când modelul spune high, are şanse decente să fie corect. Modelul confundă multe vinuri high cu medium.

Clasa low: Toți indicatorii sunt 0.00: modelul nu a prezis deloc această clasă, ceea ce scade semnnificativ valoarea practică a modelului.

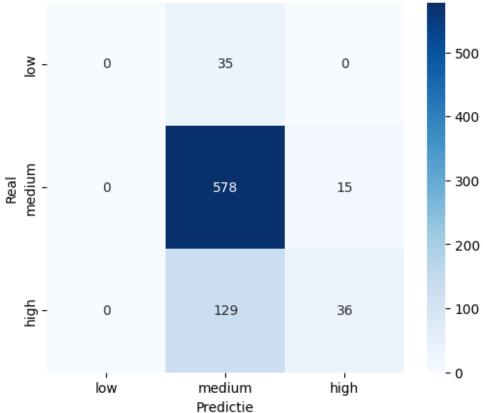
Observăm dezechilibru între clase(medium are 593 de exemple în setul de test, iar low are 35).

Confusion Matrix

```
cm = confusion_matrix(y_test, y_pred, labels=["low", "medium", "high"])
plt.figure(figsize=(6,5))
sns.heatmap(
```

```
cm,
annot=True,
fmt="d",
cmap="Blues",
xticklabels=["low", "medium", "high"],
yticklabels=["low", "medium", "high"]
)
plt.xlabel("Predicţie")
plt.ylabel("Real")
plt.title("Matricea de confuzie RidgeClassifier")
plt.show()
```





Rânduri (axe verticale): Clasele reale (ground truth). Coloane (axe orizontale): Clasele prezise de model. Valorile din interior sunt numărul de instanțe clasificate în acel mod.

Clasa low: 0 au fost prezise corect ca low, 35 au fost prezise greșit ca medium, 0 au fost prezise ca high.

Clasa medium: 578 au fost prezise corect ca medium, 15 au fost prezise greșit ca high, 0 au fost prezise ca low.

Clasa high: 36 au fost prezise corect ca high, 129 au fost greșit clasificate ca medium, 0 au fost clasificate ca low.

ROC_AUC Score

```
ROC AUC Score (macro-average, OVR): 0.5582
```

ROC = Receiver Operating Characteristic

AUC = Area Under the Curve

Curba ROC reprezintă: Rata de Adevărate Pozitive (TPR) (recall) în funcție de Rata de Fals Pozitive (FPR) pentru diferite praguri de decizie.

Aceasta măsoară cât de bine poate modelul să distingă între clase – adică cât de bine sunt separabile predicțiile.

AUC este un scor cuprins între 0 și 1.

Scorul ROC AUC (macro-medie, OVR): 0.5582.

Rezultatul arată că modelul este mai bun decât o ghicire aleatoare.

Matthews Correlation Coefficient (MCC)

```
# sklearn.metrics import matthews_corrcoef a fost importat.
mcc = matthews_corrcoef(y_test, y_pred)
print(f"MCC: {mcc:.4f}")
```

MCC: 0.2805

Spre deosebire de acuratețe, MCC ține cont de toate valorile din matricea de confuzie: TP, TN, FP, FN pentru toate clasele, nu pune accent pe clasa majoritară, deci este util în clasele dezechilibrate și oferă un scor unic care reflectă calitatea generală a predicției.

Modelul este oarecum mai bun decât o ghicire aleatoare, dar nu este foarte fiabil. Există o corelație moderată între etichetele prezise și cele reale.

Performanța este afectată în special de: recall = 0 pentru clasa low și numeroase clasificări greșite între clasele high și medium.

3 Model Optimization

Acuratețea modelului RidgeClassifier pe grupuri: 77.55%

Classification Report:

	precision	recall	f1-score	support
high low	0.72	0.22	0.33	165 35
medium	0.78	0.98	0.87	593
accuracy			0.78	793
macro avg	0.50	0.40	0.40	793
weighted avg	0.73	0.78	0.72	793

/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))

```
model = RidgeClassifier(alpha=5.0, random_state=42, max_iter=5)
model.fit(X_train_scaled, y_train)
y_pred = model.predict(X_test_scaled)
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului RidgeClassifier pe grupuri: {:.2f}%".

sformat(accuracy * 100))
```

```
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

Acuratețea modelului RidgeClassifier pe grupuri: 77.55%

Classification Report:

	precision	recall	f1-score	support
high	0.72	0.22	0.33	165
low	0.00	0.00	0.00	35
medium	0.78	0.98	0.87	593
accuracy			0.78	793
macro avg	0.50	0.40	0.40	793
weighted avg	0.73	0.78	0.72	793

/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))

Acuratețea modelului RidgeClassifier pe grupuri: 53.47%

Classification Report:

precision recall f1-score support

high	0.41	0.82	0.55	165
low	0.13	0.66	0.22	35
medium	0.91	0.45	0.60	593
accuracy			0.53	793
macro avg	0.48	0.64	0.46	793
weighted avg	0.77	0.53	0.57	793

```
model = RidgeClassifier(alpha=20.0, random_state=42)
model.fit(X_train_scaled, y_train)
y_pred = model.predict(X_test_scaled)
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului RidgeClassifier pe grupuri: {:.2f}%".

-format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

Acuratețea modelului RidgeClassifier pe grupuri: 77.55%

Classification Report:

	precision	recall	f1-score	support
high	0.73	0.21	0.33	165
low	0.00	0.00	0.00	35
medium	0.78	0.98	0.87	593
accuracy			0.78	793
macro avg	0.50	0.40	0.40	793
weighted avg	0.73	0.78	0.72	793

/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))

Acuratețea modelului RidgeClassifier pe grupuri: 77.55%

Classification Report:

	precision	recall	f1-score	support
high	0.72	0.22	0.33	165
low	0.00	0.00	0.00	35
medium	0.78	0.98	0.87	593
accuracy			0.78	793
macro avg	0.50	0.40	0.40	793
weighted avg	0.73	0.78	0.72	793

/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565: UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels
with no predicted samples. Use `zero_division` parameter to control this
behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
/usr/local/lib/python3.11/dist-packages/sklearn/metrics/_classification.py:1565:
UndefinedMetricWarning: Precision is ill-defined and being set to 0.0 in labels with no predicted samples. Use `zero_division` parameter to control this behavior.

_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))

ADASYN Model

```
from imblearn.over_sampling import ADASYN
```

4 ADASYN (Suprasampling utilizând algoritmul Adaptive Synthetic)

Această metodă este similară cu SMOTE, dar generează un număr diferit de exemple sintetice în funcție de o estimare a distribuției locale a clasei care trebuie suprasamplată.

n_neighbors (int sau obiect estimator, implicit=5): numărul de vecini apropiați folosiți pentru a defini vecinătatea esantioanelor utilizate în generarea noilor exemple sintetice.

sampling_strategy (float, str, dict sau callable, implicit='auto'). Informații despre modul de resampling al setului de date: ##### • 'minority': resamplează doar clasa minoritară; ##### • 'not minority': resamplează toate clasele cu excepția clasei minoritare; ##### • 'not majority': resamplează toate clasele cu excepția clasei majoritare; ##### • 'all': resamplează toate clasele; ##### • 'auto': echivalent cu 'not majority'.

```
Distribuție după ADASYN:
Counter({'medium': 2370, 'low': 2341, 'high': 660})
```

```
model = RidgeClassifier(alpha=5.0, random_state=42)
model.fit(X_train_resampled, y_train_resampled)

y_pred = model.predict(X_test_scaled)

accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului RidgeClassifier cu ADASYN: {:.2f}%".

format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

Acuratețea modelului RidgeClassifier cu ADASYN: 60.28%

	precision	recall	f1-score	support
high	0.80	0.12	0.21	165
low	0.12	0.69	0.21	35
medium	0.76	0.73	0.75	593
accuracy			0.60	793

macro	avg	0.56	0.51	0.39	793
weighted	avg	0.74	0.60	0.61	793

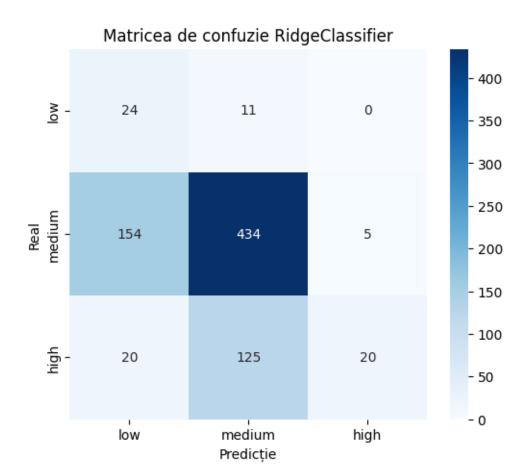
Clasa high: Precizie mare (0.80): atunci când modelul prezice high, de obicei are dreptate. Recall foarte scăzut (0.12): majoritatea vinurilor de calitate high nu este detectată. Modelul este foarte precaut în a prezice clasa high.

Clasa medium: Precizie și recall rezonabile (~0.75 fiecare). Rămâne cea mai stabilă clasă, dar nu mai este dominantă ca înainte de aplicarea ADASYN.

Clasa low: Precizie scăzută (0.12): multe dintre predicțiile pentru low sunt incorecte. Recall mare (0.69): majoritatea probelor reale low sunt detectate.

```
cm = confusion_matrix(y_test, y_pred, labels=["low", "medium", "high"])

plt.figure(figsize=(6,5))
sns.heatmap(
    cm,
    annot=True,
    fmt="d",
    cmap="Blues",
    xticklabels=["low", "medium", "high"],
    yticklabels=["low", "medium", "high"]
)
plt.xlabel("Predicţie")
plt.ylabel("Real")
plt.title("Matricea de confuzie RidgeClassifier")
plt.show()
```



ROC AUC Score (macro-average, OVR): 0.6035

ROC_AUC Score se îmbunățătește dupa adăugarea de exemple în clasele minoritare.

```
Distribuție după ADASYN:
Counter({'high': 2383, 'medium': 2370, 'low': 2341})
```

Acuratețea modelului RidgeClassifier cu ADASYN: 49.43%

Classification Report:

	precision	recall	f1-score	support
high	0.39	0.82	0.53	165
low	0.12	0.63	0.20	35
medium	0.90	0.39	0.55	593
accuracy			0.49	793
macro avg	0.47	0.62	0.43	793
weighted avg	0.76	0.49	0.53	793

5 XGBoost

XGBoost face parte din familia algoritmilor de tip boosting, care sunt tehnici de învățare prin asamblare ce combină predicțiile mai multor învățători slabi. Acesta construiește arbori de decizie secvențial/iterativ, fiecare arbore nou corectând erorile făcute de arborii anteriori, iar modelul final este un asamblu de învățători slabi (arbori de decizie) combinați pentru a forma un predictor puternic. Se fac regularizările L1 și L2 pentru a face modelul mai bun împotriva overfitting-ului. XGBoost umple automat valorile lipsă. Pentru a decide cum să construiască fiecare arbore, XGBoost utilizează o aproximare de ordinul 2 a funcției de pierdere (loss), care implică atât gradientul (derivate de ordinul 1), cât și hessianul (derivate de ordinul 2). Această abordare permite modelului să evalueze direcția în care trebuie ajustate predicțiile (prin gradient), dar și câtă încredere să aibă în aceste ajustări (prin hessian), contribuind la o convergență mai rapidă și mai stabilă a modelului.

```
import pandas as pd
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler, LabelEncoder
```

```
from sklearn.metrics import accuracy_score, classification_report,__
__matthews_corrcoef, roc_auc_score
from xgboost import XGBClassifier
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
import matplotlib.pyplot as plt
from sklearn.preprocessing import label_binarize
```

```
# Split în 70% train, 10% val, 20% test
train_val_df, test_df = train_test_split(
    white_df,
    test_size=0.2,
    random_state=42,
    stratify=white_df["quality"]
)

train_df, val_df = train_test_split(
    train_val_df,
    test_size=0.125,
    random_state=42,
    stratify=train_val_df["quality"]
)
```

```
def map_quality(q):
    if q in [3, 4]:
        return "low"
    elif q in [5, 6]:
        return "medium"
    else:
        return "high"

for df in [train_df, val_df, test_df]:
    df["quality_group"] = df["quality"].apply(map_quality)
```

6 Baseline model

```
X_train = train_df.drop(["quality", "quality_group"], axis=1)
y_train = train_df["quality_group"]

X_val = val_df.drop(["quality", "quality_group"], axis=1)
y_val = val_df["quality_group"]

X_test = test_df.drop(["quality", "quality_group"], axis=1)
y_test = test_df["quality_group"]
```

```
le = LabelEncoder() # pentru a converti etichetele low, medium și high în 0, 1

s, i 2.

y_train_enc = le.fit_transform(y_train)

y_val_enc = le.transform(y_val)

y_test_enc = le.transform(y_test)

scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)

X_val_scaled = scaler.transform(X_val)

X_test_scaled = scaler.transform(X_test)
```

```
#!pip install --upgrade xgboost
import xgboost
print(xgboost.__version__)
print("XGBClassifier path:", XGBClassifier.__module__)
#help(XGBClassifier.fit)
```

3.0.2 XGBClassifier path: xgboost.sklearn

```
model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=7,
    subsample=1.0,
    objective='multi:softprob',
    num_class=3,
    use_label_encoder=False,
    eval_metric='mlogloss',
    verbosity=0,
    min_child_weight=1
)
```

```
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_scaled,
    y_train_enc,
    eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
)
```

```
[0]
       validation_0-mlogloss:1.01143
                                        validation_1-mlogloss:1.02021
       validation 0-mlogloss:0.93622
                                        validation 1-mlogloss:0.95506
[1]
                                        validation_1-mlogloss:0.89988
[2]
       validation_0-mlogloss:0.87022
       validation_0-mlogloss:0.81256
                                        validation_1-mlogloss:0.85309
[3]
[4]
       validation_0-mlogloss:0.76296
                                        validation_1-mlogloss:0.81105
       validation_0-mlogloss:0.71894
[5]
                                        validation_1-mlogloss:0.77516
[6]
       validation_0-mlogloss:0.67990
                                        validation_1-mlogloss:0.74462
```

```
[7]
        validation_0-mlogloss:0.64556
                                         validation_1-mlogloss:0.71828
[8]
        validation_0-mlogloss:0.61318
                                         validation_1-mlogloss:0.69487
[9]
        validation_0-mlogloss:0.58441
                                         validation_1-mlogloss:0.67507
[10]
        validation 0-mlogloss:0.55922
                                         validation 1-mlogloss:0.65653
                                         validation 1-mlogloss:0.63972
[11]
        validation 0-mlogloss:0.53549
[12]
        validation 0-mlogloss:0.51426
                                         validation 1-mlogloss:0.62490
[13]
        validation 0-mlogloss:0.49445
                                         validation 1-mlogloss:0.61277
[14]
        validation 0-mlogloss:0.47641
                                         validation_1-mlogloss:0.60026
[15]
        validation 0-mlogloss:0.45965
                                         validation 1-mlogloss:0.58941
[16]
        validation_0-mlogloss:0.44436
                                         validation_1-mlogloss:0.58060
[17]
        validation_0-mlogloss:0.43127
                                         validation_1-mlogloss:0.57172
[18]
        validation_0-mlogloss:0.41863
                                         validation_1-mlogloss:0.56550
[19]
        validation_0-mlogloss:0.40678
                                         validation_1-mlogloss:0.55950
[20]
        validation_0-mlogloss:0.39591
                                         validation_1-mlogloss:0.55490
[21]
        validation_0-mlogloss:0.38466
                                         validation_1-mlogloss:0.55089
[22]
        validation_0-mlogloss:0.37523
                                         validation_1-mlogloss:0.54653
[23]
        validation_0-mlogloss:0.36625
                                         validation_1-mlogloss:0.54273
[24]
        validation_0-mlogloss:0.35749
                                         validation_1-mlogloss:0.54058
[25]
        validation 0-mlogloss:0.34958
                                         validation_1-mlogloss:0.53852
[26]
        validation 0-mlogloss:0.34223
                                         validation 1-mlogloss:0.53659
        validation 0-mlogloss:0.33399
                                         validation 1-mlogloss:0.53389
[27]
                                         validation_1-mlogloss:0.52994
[28]
        validation 0-mlogloss:0.32690
        validation_0-mlogloss:0.31957
[29]
                                         validation_1-mlogloss:0.52801
[30]
        validation_0-mlogloss:0.31335
                                         validation_1-mlogloss:0.52576
[31]
        validation_0-mlogloss:0.30745
                                         validation_1-mlogloss:0.52467
[32]
        validation_0-mlogloss:0.30214
                                         validation_1-mlogloss:0.52151
[33]
                                         validation_1-mlogloss:0.52001
        validation_0-mlogloss:0.29783
[34]
        validation_0-mlogloss:0.29351
                                         validation_1-mlogloss:0.51859
[35]
                                         validation 1-mlogloss:0.51729
        validation 0-mlogloss:0.28886
[36]
        validation_0-mlogloss:0.28458
                                         validation_1-mlogloss:0.51667
[37]
        validation_0-mlogloss:0.28108
                                         validation_1-mlogloss:0.51601
        validation_0-mlogloss:0.27762
[38]
                                         validation_1-mlogloss:0.51527
[39]
        validation_0-mlogloss:0.27322
                                         validation_1-mlogloss:0.51415
[40]
        validation 0-mlogloss:0.26866
                                         validation_1-mlogloss:0.51399
[41]
        validation 0-mlogloss:0.26539
                                         validation 1-mlogloss:0.51337
[42]
        validation 0-mlogloss:0.26147
                                         validation 1-mlogloss:0.51294
[43]
        validation 0-mlogloss:0.25831
                                         validation 1-mlogloss:0.51328
[44]
        validation 0-mlogloss:0.25495
                                         validation_1-mlogloss:0.51340
[45]
        validation_0-mlogloss:0.25202
                                         validation_1-mlogloss:0.51343
[46]
        validation_0-mlogloss:0.24949
                                         validation_1-mlogloss:0.51288
[47]
        validation_0-mlogloss:0.24631
                                         validation_1-mlogloss:0.51222
[48]
        validation_0-mlogloss:0.24388
                                         validation_1-mlogloss:0.51205
[49]
        validation_0-mlogloss:0.24058
                                         validation_1-mlogloss:0.51134
                                         validation 1-mlogloss:0.51054
[50]
        validation_0-mlogloss:0.23698
[51]
        validation_0-mlogloss:0.23492
                                         validation_1-mlogloss:0.51032
[52]
        validation_0-mlogloss:0.23275
                                         validation_1-mlogloss:0.51014
[53]
        validation_0-mlogloss:0.22986
                                         validation_1-mlogloss:0.50925
[54]
        validation_0-mlogloss:0.22810
                                         validation_1-mlogloss:0.50935
```

```
[55]
        validation_0-mlogloss:0.22578
                                        validation_1-mlogloss:0.50885
[56]
        validation_0-mlogloss:0.22424
                                        validation_1-mlogloss:0.50941
        validation_0-mlogloss:0.22166
                                        validation_1-mlogloss:0.50903
[57]
[58]
        validation 0-mlogloss:0.21811
                                        validation 1-mlogloss:0.51062
                                        validation 1-mlogloss:0.51086
        validation 0-mlogloss:0.21570
[59]
[60]
        validation 0-mlogloss:0.21411
                                        validation 1-mlogloss:0.51071
[61]
        validation 0-mlogloss:0.21204
                                        validation 1-mlogloss:0.51033
        validation 0-mlogloss:0.21028
                                        validation_1-mlogloss:0.51040
[62]
[63]
        validation 0-mlogloss:0.20844
                                        validation 1-mlogloss:0.51073
[64]
        validation_0-mlogloss:0.20664
                                        validation_1-mlogloss:0.51073
XGBClassifier(base_score=None, booster=None, callbacks=None,
              colsample bylevel=None, colsample bynode=None,
              colsample_bytree=None, device=None, early_stopping_rounds=10,
              enable categorical=False, eval metric='mlogloss',
              feature_types=None, feature_weights=None, gamma=None,
              grow policy=None, importance type=None,
              interaction constraints=None, learning rate=0.1, max_bin=None,
              max_cat_threshold=None, max_cat_to_onehot=None,
              max_delta_step=None, max_depth=7, max_leaves=None,
              min_child_weight=1, missing=nan, monotone_constraints=None,
              multi_strategy=None, n_estimators=200, n_jobs=None, num_class=3,
...)
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)
# === Evaluare
accuracy = accuracy_score(y_test, y_pred)
print("\nAcuratetea modelului XGBoost cu early stopping: {:.2f}%".
  ⇔format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

Acuratețea modelului XGBoost cu early stopping: 77.18%

	precision	recall	f1-score	support
high	0.60	0.38	0.46	165
low	0.29	0.06	0.10	35
medium	0.80	0.92	0.86	593
accuracy			0.77	793
macro avg	0.56	0.45	0.47	793
weighted avg	0.74	0.77	0.74	793

Din cele 793 de exemple din setul de test:

Aproximativ 612 au fost clasificate corect. Acuratețea este bună, dar nu suficientă pentru a evalua corect un model în cazul unui dezechilibru între clase, cum este cazul aici.

Clasa high: precision = 0.60: 60% dintre predicțiile "high" au fost corecte.recall = 0.38: doar 38% din exemplele "high" au fost recunoscute corect.

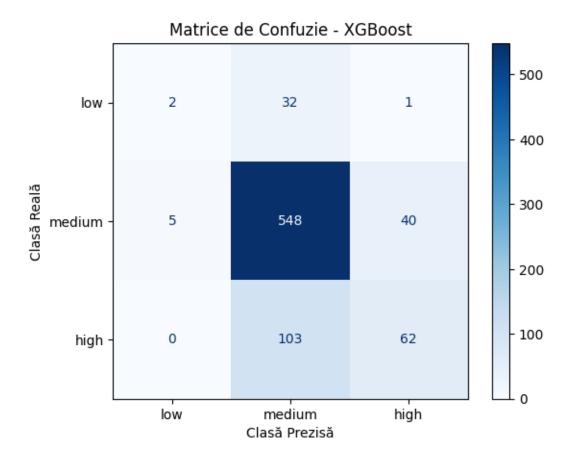
Clasa medium: precision = 0.80: 80% dintre predicțiile "medium" au fost corecte. recall = 0.92: 92% din toate instanțele "medium" au fost recunoscute corect. f1-score = 0.86: scor foarte bun, modelul învață bine clasa aceasta.

Clasa low: precision = 0.29: 29% dintre predicțiile "low" au fost corecte. recall = 0.06: doar 6% dintre exemplele reale low au fost recunoscute, f1-score foarte slab (0.10).

Macro avg: media simplă între clase, tratate egal (utilă când clasele sunt dezechilibrate). Macro avg = scăzut, semn că modelul nu generalizează bine pe toate clasele.

Weighted avg: ține cont de mărimea fiecărei clase, dominată de medium. Weighted avg = înalt, dar maschează performanța slabă pe clasele mici.

Confusion Matrix



ROC_AUC Score

ROC AUC (OvR, macro average): 0.3289

Un scor de 0.3289 este sub 0.5, ceea ce sugerează că:

Modelul nu produce probabilități bine calibrate. Nu distinge clar între clasele low, medium, high. Ar putea fi supraspecializat pe clasa medium (cea dominantă), ignorând low și high. Modelul suferă de dezechilibru între clase, ceea ce afectează scorul ROC AUC.

Acuratețea este \sim 77%, dar ROC AUC e 0.33 ceea ce semnalează un model dezechilibrat care poate

prezice doar bine clasa majoritară (medium), dar slab celelalte.

Matthews Correlation Coefficient (MCC)

```
mcc = matthews_corrcoef(y_test, y_pred)
print(f"Matthews Correlation Coefficient (MCC): {mcc:.4f}")
```

```
Matthews Correlation Coefficient (MCC): 0.3246
```

Valoarea este peste 0, deci modelul face mai bine decât o clasificare aleatorie. Dar nu depășește pragul de 0.5, ceea ce sugerează că modelul are performanță modestă, reușește parțial să distingă clasele (low, medium, high), dar greșește frecvent, mai ales la clasele minoritare (low și high). Probabil este puternic influențat de clasa majoritară medium.

7 Model Optimization

```
model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=7,
    subsample=1.0,
    objective='multi:softprob',
    num_class=3,
    use label encoder=False,
    eval_metric='merror',
    verbosity=0,
    min_child_weight=1
)
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_scaled,
    y_train_enc,
    eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)
# === Evaluare
accuracy = accuracy_score(y_test, y_pred)
print("\nAcuratetea modelului XGBoost cu early stopping: {:.2f}%".
 ⇔format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

```
[0] validation_0-merror:0.16198 validation_1-merror:0.21465
[1] validation_0-merror:0.15476 validation_1-merror:0.21465
```

```
[2]
       validation_0-merror:0.14755
                                        validation_1-merror:0.22222
[3]
       validation_0-merror:0.14105
                                        validation_1-merror:0.23232
[4]
       validation_0-merror:0.13528
                                        validation_1-merror:0.22727
[5]
       validation_0-merror:0.13456
                                        validation_1-merror:0.22475
[6]
       validation 0-merror:0.13203
                                        validation 1-merror:0.22222
                                        validation_1-merror:0.21717
[7]
       validation 0-merror:0.13167
[8]
        validation 0-merror:0.12843
                                        validation 1-merror:0.21970
                                        validation_1-merror:0.22475
        validation_0-merror:0.12626
[9]
[10]
        validation_0-merror:0.12590
                                        validation_1-merror:0.22727
```

Acuratețea modelului XGBoost cu early stopping: 75.79%

	precision	recall	f1-score	support
high	0.54	0.36	0.43	165
low	0.20	0.03	0.05	35
medium	0.80	0.91	0.85	593
accuracy			0.76	793
macro avg	0.51	0.43	0.44	793
weighted avg	0.72	0.76	0.73	793

```
model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=7,
    subsample=1.0,
    objective='multi:softmax',
    num_class=3,
    use_label_encoder=False,
    eval_metric='mlogloss',
    verbosity=0,
    min_child_weight=1
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_scaled,
    y_train_enc,
    eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)
# === Evaluare
```

```
[0]
        validation_0-mlogloss:1.01143
                                         validation_1-mlogloss:1.02021
[1]
        validation_0-mlogloss:0.93622
                                         validation_1-mlogloss:0.95506
[2]
        validation_0-mlogloss:0.87022
                                         validation_1-mlogloss:0.89988
[3]
        validation_0-mlogloss:0.81256
                                         validation_1-mlogloss:0.85309
Γ4]
        validation 0-mlogloss:0.76296
                                         validation 1-mlogloss:0.81105
[5]
        validation_0-mlogloss:0.71894
                                         validation_1-mlogloss:0.77516
[6]
        validation 0-mlogloss:0.67990
                                         validation 1-mlogloss:0.74462
                                         validation 1-mlogloss:0.71828
[7]
        validation 0-mlogloss:0.64556
[8]
        validation 0-mlogloss:0.61318
                                         validation 1-mlogloss:0.69487
       validation_0-mlogloss:0.58441
[9]
                                         validation_1-mlogloss:0.67507
[10]
        validation 0-mlogloss:0.55922
                                         validation_1-mlogloss:0.65653
[11]
        validation_0-mlogloss:0.53549
                                         validation_1-mlogloss:0.63972
[12]
        validation_0-mlogloss:0.51426
                                         validation_1-mlogloss:0.62490
[13]
        validation_0-mlogloss:0.49445
                                         validation_1-mlogloss:0.61277
[14]
        validation_0-mlogloss:0.47641
                                         validation_1-mlogloss:0.60026
[15]
                                         validation_1-mlogloss:0.58941
        validation_0-mlogloss:0.45965
[16]
        validation_0-mlogloss:0.44436
                                         validation_1-mlogloss:0.58060
[17]
        validation_0-mlogloss:0.43127
                                         validation_1-mlogloss:0.57172
[18]
        validation_0-mlogloss:0.41863
                                         validation_1-mlogloss:0.56550
[19]
        validation_0-mlogloss:0.40678
                                         validation_1-mlogloss:0.55950
[20]
        validation_0-mlogloss:0.39591
                                         validation_1-mlogloss:0.55490
[21]
                                         validation 1-mlogloss:0.55089
        validation 0-mlogloss:0.38466
[22]
        validation 0-mlogloss:0.37523
                                         validation 1-mlogloss:0.54653
Γ231
                                         validation 1-mlogloss:0.54273
        validation 0-mlogloss:0.36625
[24]
        validation_0-mlogloss:0.35749
                                         validation_1-mlogloss:0.54058
[25]
        validation 0-mlogloss:0.34958
                                         validation 1-mlogloss:0.53852
[26]
        validation_0-mlogloss:0.34223
                                         validation_1-mlogloss:0.53659
[27]
        validation_0-mlogloss:0.33399
                                         validation_1-mlogloss:0.53389
[28]
                                         validation_1-mlogloss:0.52994
        validation_0-mlogloss:0.32690
[29]
        validation_0-mlogloss:0.31957
                                         validation_1-mlogloss:0.52801
[30]
        validation_0-mlogloss:0.31335
                                         validation_1-mlogloss:0.52576
[31]
        validation_0-mlogloss:0.30745
                                         validation_1-mlogloss:0.52467
[32]
        validation_0-mlogloss:0.30214
                                         validation_1-mlogloss:0.52151
[33]
        validation_0-mlogloss:0.29783
                                         validation_1-mlogloss:0.52001
[34]
        validation_0-mlogloss:0.29351
                                         validation_1-mlogloss:0.51859
[35]
        validation 0-mlogloss:0.28886
                                         validation_1-mlogloss:0.51729
                                         validation 1-mlogloss:0.51667
[36]
        validation 0-mlogloss:0.28458
[37]
        validation 0-mlogloss:0.28108
                                         validation_1-mlogloss:0.51601
[38]
        validation 0-mlogloss:0.27762
                                         validation 1-mlogloss:0.51527
[39]
        validation 0-mlogloss:0.27322
                                         validation_1-mlogloss:0.51415
[40]
        validation 0-mlogloss:0.26866
                                         validation 1-mlogloss:0.51399
```

```
[41]
        validation_0-mlogloss:0.26539
                                         validation_1-mlogloss:0.51337
[42]
        validation_0-mlogloss:0.26147
                                         validation_1-mlogloss:0.51294
[43]
        validation_0-mlogloss:0.25831
                                         validation_1-mlogloss:0.51328
[44]
        validation 0-mlogloss:0.25495
                                         validation 1-mlogloss:0.51340
        validation 0-mlogloss:0.25202
                                         validation 1-mlogloss:0.51343
[45]
[46]
        validation 0-mlogloss:0.24949
                                         validation 1-mlogloss:0.51288
        validation 0-mlogloss:0.24631
                                         validation 1-mlogloss:0.51222
[47]
        validation 0-mlogloss:0.24388
                                         validation_1-mlogloss:0.51205
[48]
[49]
        validation 0-mlogloss:0.24058
                                         validation 1-mlogloss:0.51134
[50]
        validation_0-mlogloss:0.23698
                                         validation_1-mlogloss:0.51054
[51]
        validation_0-mlogloss:0.23492
                                         validation_1-mlogloss:0.51032
[52]
        validation_0-mlogloss:0.23275
                                         validation_1-mlogloss:0.51014
[53]
        validation_0-mlogloss:0.22986
                                         validation_1-mlogloss:0.50925
        validation_0-mlogloss:0.22810
                                         validation_1-mlogloss:0.50935
[54]
[55]
        validation_0-mlogloss:0.22578
                                         validation_1-mlogloss:0.50885
        validation_0-mlogloss:0.22424
                                         validation_1-mlogloss:0.50941
[56]
[57]
        validation_0-mlogloss:0.22166
                                         validation_1-mlogloss:0.50903
        validation_0-mlogloss:0.21811
                                         validation_1-mlogloss:0.51062
[58]
[59]
        validation 0-mlogloss:0.21570
                                         validation_1-mlogloss:0.51086
        validation 0-mlogloss:0.21411
                                         validation 1-mlogloss:0.51071
[60]
        validation 0-mlogloss:0.21204
                                         validation 1-mlogloss:0.51033
[61]
[62]
        validation 0-mlogloss:0.21028
                                         validation 1-mlogloss:0.51040
        validation 0-mlogloss:0.20844
                                         validation 1-mlogloss:0.51073
[63]
        validation_0-mlogloss:0.20664
[64]
                                         validation_1-mlogloss:0.51073
[65]
        validation_0-mlogloss:0.20493
                                         validation_1-mlogloss:0.51067
```

Acuratețea modelului XGBoost cu early stopping: 77.18%

	precision	recall	f1-score	support
high low medium	0.60 0.29 0.80	0.38 0.06 0.92	0.46 0.10 0.86	165 35 593
accuracy macro avg weighted avg	0.56 0.74	0.45 0.77	0.77 0.47 0.74	793 793 793

```
model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=7,
    subsample=0.8,
    objective='multi:softprob',
    num_class=3,
```

```
use_label_encoder=False,
    eval_metric='mlogloss',
    verbosity=0,
    min_child_weight=1
)
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_scaled,
    y train enc,
    eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
)
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)
# === Evaluare
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului XGBoost cu early stopping: {:.2f}%".
 ⇔format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
[0]
                                        validation_1-mlogloss:1.02230
       validation_0-mlogloss:1.01288
[1]
```

```
validation_0-mlogloss:0.93890
                                        validation_1-mlogloss:0.96005
[2]
        validation_0-mlogloss:0.87334
                                        validation_1-mlogloss:0.90420
[3]
        validation_0-mlogloss:0.81767
                                        validation_1-mlogloss:0.85811
        validation_0-mlogloss:0.76834
                                        validation_1-mlogloss:0.81540
[4]
                                        validation 1-mlogloss:0.78052
[5]
        validation 0-mlogloss:0.72527
[6]
        validation 0-mlogloss:0.68627
                                        validation 1-mlogloss:0.74926
[7]
        validation 0-mlogloss:0.65124
                                        validation 1-mlogloss:0.72247
[8]
        validation_0-mlogloss:0.61924
                                        validation_1-mlogloss:0.69740
[9]
        validation 0-mlogloss:0.58892
                                        validation 1-mlogloss:0.67503
[10]
                                        validation_1-mlogloss:0.65774
        validation_0-mlogloss:0.56287
[11]
        validation_0-mlogloss:0.53916
                                        validation_1-mlogloss:0.64055
[12]
        validation_0-mlogloss:0.51800
                                        validation_1-mlogloss:0.62476
[13]
        validation_0-mlogloss:0.49854
                                        validation_1-mlogloss:0.61159
[14]
        validation_0-mlogloss:0.47892
                                        validation_1-mlogloss:0.59927
                                        validation_1-mlogloss:0.59027
[15]
        validation_0-mlogloss:0.46235
[16]
        validation_0-mlogloss:0.44726
                                        validation_1-mlogloss:0.57924
[17]
        validation_0-mlogloss:0.43374
                                        validation_1-mlogloss:0.57081
[18]
        validation_0-mlogloss:0.42060
                                        validation_1-mlogloss:0.56345
        validation_0-mlogloss:0.40866
[19]
                                        validation_1-mlogloss:0.55782
        validation 0-mlogloss:0.39726
                                        validation 1-mlogloss:0.55099
[20]
[21]
        validation 0-mlogloss:0.38502
                                        validation_1-mlogloss:0.54546
[22]
        validation 0-mlogloss:0.37418
                                        validation 1-mlogloss:0.54085
                                        validation_1-mlogloss:0.53641
Γ231
        validation_0-mlogloss:0.36499
[24]
        validation 0-mlogloss:0.35663
                                        validation 1-mlogloss:0.53047
```

```
[25]
        validation_0-mlogloss:0.34904
                                         validation_1-mlogloss:0.52672
[26]
        validation_0-mlogloss:0.34091
                                         validation_1-mlogloss:0.52452
[27]
        validation_0-mlogloss:0.33108
                                         validation_1-mlogloss:0.52054
[28]
        validation 0-mlogloss:0.32418
                                         validation 1-mlogloss:0.51726
        validation 0-mlogloss:0.31670
                                         validation 1-mlogloss:0.51699
[29]
[30]
        validation 0-mlogloss:0.30813
                                         validation 1-mlogloss:0.51382
                                         validation 1-mlogloss:0.51202
[31]
        validation 0-mlogloss:0.30178
        validation 0-mlogloss:0.29617
                                         validation_1-mlogloss:0.51095
[32]
[33]
        validation 0-mlogloss:0.29102
                                         validation 1-mlogloss:0.50882
[34]
        validation_0-mlogloss:0.28599
                                         validation_1-mlogloss:0.50582
[35]
        validation_0-mlogloss:0.28069
                                         validation_1-mlogloss:0.50463
[36]
        validation_0-mlogloss:0.27625
                                         validation_1-mlogloss:0.50325
[37]
        validation_0-mlogloss:0.27205
                                         validation_1-mlogloss:0.50287
                                         validation_1-mlogloss:0.50344
[38]
        validation_0-mlogloss:0.26833
[39]
        validation_0-mlogloss:0.26355
                                         validation_1-mlogloss:0.50351
[40]
        validation_0-mlogloss:0.26027
                                         validation_1-mlogloss:0.50252
[41]
        validation_0-mlogloss:0.25470
                                         validation_1-mlogloss:0.50019
[42]
        validation_0-mlogloss:0.25068
                                         validation_1-mlogloss:0.50170
[43]
        validation 0-mlogloss:0.24626
                                         validation 1-mlogloss:0.50128
                                         validation 1-mlogloss:0.50063
Γ44]
        validation 0-mlogloss:0.24343
        validation 0-mlogloss:0.23982
                                         validation 1-mlogloss:0.49996
[45]
                                         validation_1-mlogloss:0.50011
[46]
        validation 0-mlogloss:0.23583
[47]
        validation_0-mlogloss:0.23361
                                         validation_1-mlogloss:0.49962
[48]
        validation 0-mlogloss:0.22980
                                         validation_1-mlogloss:0.49839
[49]
        validation_0-mlogloss:0.22579
                                         validation_1-mlogloss:0.49722
[50]
        validation_0-mlogloss:0.22298
                                         validation_1-mlogloss:0.49753
[51]
        validation_0-mlogloss:0.22072
                                         validation_1-mlogloss:0.49829
[52]
        validation_0-mlogloss:0.21873
                                         validation_1-mlogloss:0.49746
[53]
                                         validation 1-mlogloss:0.49755
        validation 0-mlogloss:0.21642
[54]
        validation_0-mlogloss:0.21337
                                         validation_1-mlogloss:0.49790
[55]
        validation_0-mlogloss:0.21047
                                         validation_1-mlogloss:0.49844
[56]
        validation_0-mlogloss:0.20748
                                         validation_1-mlogloss:0.49683
[57]
        validation_0-mlogloss:0.20465
                                         validation_1-mlogloss:0.49626
[58]
        validation 0-mlogloss:0.20237
                                         validation 1-mlogloss:0.49617
[59]
        validation 0-mlogloss:0.19930
                                         validation 1-mlogloss:0.49615
[60]
        validation 0-mlogloss:0.19745
                                         validation 1-mlogloss:0.49736
                                         validation 1-mlogloss:0.49854
[61]
        validation 0-mlogloss:0.19447
[62]
        validation 0-mlogloss:0.19244
                                         validation_1-mlogloss:0.49864
[63]
        validation_0-mlogloss:0.18960
                                         validation_1-mlogloss:0.49843
[64]
        validation_0-mlogloss:0.18680
                                         validation_1-mlogloss:0.49834
[65]
        validation_0-mlogloss:0.18563
                                         validation_1-mlogloss:0.49823
        validation_0-mlogloss:0.18204
                                         validation_1-mlogloss:0.49824
[66]
[67]
        validation_0-mlogloss:0.17925
                                         validation_1-mlogloss:0.49856
[68]
        validation_0-mlogloss:0.17767
                                         validation_1-mlogloss:0.49802
```

Acuratețea modelului XGBoost cu early stopping: 77.81%

	precision	recall	f1-score	support
high	0.63	0.38	0.47	165
low	0.43	0.09	0.14	35
medium	0.80	0.93	0.86	593
accuracy			0.78	793
macro avg	0.62	0.46	0.49	793
weighted avg	0.75	0.78	0.75	793

Varianta de mai sus a performat mai bine decât modelul de bază.

```
model = XGBClassifier(
    n estimators=200,
    learning_rate=0.1,
    max depth=12,
    subsample=0.8,
    objective='multi:softmax',
    num_class=3,
    use_label_encoder=False,
    eval_metric='mlogloss',
    verbosity=0,
    min_child_weight=3
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_scaled,
    y_train_enc,
    eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
)
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)
# === Evaluare
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului XGBoost cu early stopping: {:.2f}%".
 ⇔format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
[0]
       validation_0-mlogloss:1.00860
                                        validation_1-mlogloss:1.02331
```

```
[0] validation_0-mlogloss:1.00860 validation_1-mlogloss:1.02331
[1] validation_0-mlogloss:0.92954 validation_1-mlogloss:0.95751
[2] validation_0-mlogloss:0.86059 validation_1-mlogloss:0.90376
[3] validation_0-mlogloss:0.79929 validation_1-mlogloss:0.85730
[4] validation_0-mlogloss:0.74486 validation_1-mlogloss:0.81716
```

```
[5]
        validation_0-mlogloss:0.69735
                                         validation_1-mlogloss:0.78120
[6]
        validation_0-mlogloss:0.65396
                                         validation_1-mlogloss:0.75206
[7]
        validation_0-mlogloss:0.61482
                                         validation_1-mlogloss:0.72597
[8]
        validation 0-mlogloss:0.58069
                                         validation 1-mlogloss:0.69970
                                         validation 1-mlogloss:0.67895
[9]
        validation 0-mlogloss:0.54898
[10]
        validation 0-mlogloss:0.52009
                                         validation 1-mlogloss:0.66080
[11]
        validation 0-mlogloss:0.49379
                                         validation 1-mlogloss:0.64458
[12]
        validation 0-mlogloss:0.46983
                                         validation_1-mlogloss:0.63011
[13]
        validation 0-mlogloss:0.44755
                                         validation 1-mlogloss:0.61738
[14]
        validation_0-mlogloss:0.42646
                                         validation_1-mlogloss:0.60715
[15]
        validation_0-mlogloss:0.40733
                                         validation_1-mlogloss:0.59698
[16]
        validation_0-mlogloss:0.38951
                                         validation_1-mlogloss:0.58763
[17]
        validation_0-mlogloss:0.37353
                                         validation_1-mlogloss:0.57864
[18]
        validation_0-mlogloss:0.35851
                                         validation_1-mlogloss:0.56950
[19]
        validation_0-mlogloss:0.34483
                                         validation_1-mlogloss:0.56279
[20]
        validation_0-mlogloss:0.33226
                                         validation_1-mlogloss:0.55583
[21]
        validation_0-mlogloss:0.32047
                                         validation_1-mlogloss:0.54924
[22]
        validation_0-mlogloss:0.30902
                                         validation_1-mlogloss:0.54468
[23]
        validation 0-mlogloss:0.29901
                                         validation_1-mlogloss:0.53954
Γ241
        validation 0-mlogloss:0.29004
                                         validation 1-mlogloss:0.53547
        validation 0-mlogloss:0.28041
                                         validation 1-mlogloss:0.53056
[25]
                                         validation_1-mlogloss:0.52705
[26]
        validation 0-mlogloss:0.27283
        validation_0-mlogloss:0.26413
                                         validation_1-mlogloss:0.52290
[27]
[28]
        validation_0-mlogloss:0.25711
                                         validation_1-mlogloss:0.52081
[29]
        validation_0-mlogloss:0.24893
                                         validation_1-mlogloss:0.52004
[30]
        validation_0-mlogloss:0.24239
                                         validation_1-mlogloss:0.51919
[31]
                                         validation_1-mlogloss:0.51719
        validation_0-mlogloss:0.23544
[32]
        validation_0-mlogloss:0.22952
                                         validation_1-mlogloss:0.51598
[33]
                                         validation 1-mlogloss:0.51564
        validation 0-mlogloss:0.22340
[34]
        validation_0-mlogloss:0.21906
                                         validation_1-mlogloss:0.51561
[35]
        validation_0-mlogloss:0.21384
                                         validation_1-mlogloss:0.51392
        validation_0-mlogloss:0.20930
[36]
                                         validation_1-mlogloss:0.51341
[37]
        validation_0-mlogloss:0.20427
                                         validation_1-mlogloss:0.51214
[38]
        validation 0-mlogloss:0.20120
                                         validation_1-mlogloss:0.51185
[39]
        validation 0-mlogloss:0.19692
                                         validation 1-mlogloss:0.51037
[40]
        validation 0-mlogloss:0.19319
                                         validation 1-mlogloss:0.50960
[41]
        validation 0-mlogloss:0.18847
                                         validation 1-mlogloss:0.50898
[42]
        validation 0-mlogloss:0.18375
                                         validation_1-mlogloss:0.50910
[43]
        validation_0-mlogloss:0.17969
                                         validation_1-mlogloss:0.50792
[44]
        validation_0-mlogloss:0.17679
                                         validation_1-mlogloss:0.50757
[45]
        validation_0-mlogloss:0.17331
                                         validation_1-mlogloss:0.50722
[46]
        validation_0-mlogloss:0.17012
                                         validation_1-mlogloss:0.50705
[47]
        validation_0-mlogloss:0.16731
                                         validation_1-mlogloss:0.50656
                                         validation 1-mlogloss:0.50731
[48]
        validation_0-mlogloss:0.16436
[49]
        validation_0-mlogloss:0.16130
                                         validation_1-mlogloss:0.50753
[50]
        validation_0-mlogloss:0.15899
                                         validation_1-mlogloss:0.50796
[51]
        validation_0-mlogloss:0.15705
                                         validation_1-mlogloss:0.50866
[52]
        validation_0-mlogloss:0.15542
                                         validation_1-mlogloss:0.50853
```

```
[53] validation_0-mlogloss:0.15328 validation_1-mlogloss:0.50874
[54] validation_0-mlogloss:0.15005 validation_1-mlogloss:0.50929
[55] validation_0-mlogloss:0.14718 validation_1-mlogloss:0.50942
[56] validation_0-mlogloss:0.14485 validation_1-mlogloss:0.50914
[57] validation_0-mlogloss:0.14253 validation_1-mlogloss:0.50993
```

Acuratețea modelului XGBoost cu early stopping: 77.68%

Classification Report:

	precision	recall	f1-score	support
ماست ئا ما	0.61	0.20	0.47	165
high	0.61	0.38	0.47	165
low	0.40	0.06	0.10	35
medium	0.80	0.93	0.86	593
accuracy			0.78	793
macro avg	0.61	0.45	0.48	793
weighted avg	0.75	0.78	0.75	793

Această încercare a performat mai bine decât modelul de bază.

8 Adăugare ADASYN

```
adasyn = ADASYN(random_state=42, sampling_strategy="minority", n_neighbors=10)
X_train_resampled, y_train_resampled = adasyn.fit_resample(X_train_scaled,__
 →y_train_enc)
# === Model
model = XGBClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=7,
    subsample=0.8,
    objective='multi:softprob',
    num_class=3,
    use_label_encoder=False,
    eval_metric='mlogloss',
    verbosity=0,
    min_child_weight=1
model.set_params(early_stopping_rounds=10)
model.fit(
    X_train_resampled,
    y_train_resampled,
```

```
eval_set=[(X_train_scaled, y_train_enc), (X_val_scaled, y_val_enc)],
    verbose=True
)

# === Predicţie şi evaluare
y_pred_enc = model.predict(X_test_scaled)
y_pred = le.inverse_transform(y_pred_enc)

accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului XGBoost cu early stopping şi ADASYN: {:.2f}%".
    oformat(accuracy * 100))

print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

```
[0]
        validation 0-mlogloss:1.04085
                                        validation 1-mlogloss:1.05663
Γ1]
        validation_0-mlogloss:0.98589
                                        validation_1-mlogloss:1.01609
[2]
        validation 0-mlogloss:0.93900
                                        validation_1-mlogloss:0.97893
[3]
        validation_0-mlogloss:0.89573
                                        validation_1-mlogloss:0.94628
[4]
        validation_0-mlogloss:0.85706
                                        validation_1-mlogloss:0.91753
        validation_0-mlogloss:0.82090
                                        validation_1-mlogloss:0.88903
[5]
[6]
        validation_0-mlogloss:0.79020
                                        validation_1-mlogloss:0.86905
[7]
        validation_0-mlogloss:0.76222
                                        validation_1-mlogloss:0.84802
[8]
        validation_0-mlogloss:0.73794
                                        validation_1-mlogloss:0.83263
[9]
        validation_0-mlogloss:0.71228
                                        validation_1-mlogloss:0.81600
[10]
        validation_0-mlogloss:0.68782
                                        validation_1-mlogloss:0.80146
[11]
        validation_0-mlogloss:0.66542
                                        validation_1-mlogloss:0.78519
[12]
        validation_0-mlogloss:0.64606
                                        validation_1-mlogloss:0.77185
                                        validation 1-mlogloss:0.75902
Г137
        validation 0-mlogloss:0.62660
[14]
        validation 0-mlogloss:0.60764
                                        validation 1-mlogloss:0.74603
Г15Т
        validation 0-mlogloss:0.59225
                                        validation 1-mlogloss:0.73605
        validation_0-mlogloss:0.57597
                                        validation_1-mlogloss:0.72672
[16]
[17]
        validation 0-mlogloss:0.55903
                                        validation 1-mlogloss:0.71626
[18]
                                        validation_1-mlogloss:0.70838
        validation_0-mlogloss:0.54484
[19]
        validation_0-mlogloss:0.53051
                                        validation_1-mlogloss:0.70028
[20]
        validation_0-mlogloss:0.52062
                                        validation_1-mlogloss:0.69424
[21]
        validation_0-mlogloss:0.50883
                                        validation_1-mlogloss:0.68783
[22]
        validation_0-mlogloss:0.49860
                                        validation_1-mlogloss:0.68299
[23]
                                        validation_1-mlogloss:0.67779
        validation_0-mlogloss:0.48915
[24]
        validation_0-mlogloss:0.48076
                                        validation_1-mlogloss:0.67315
[25]
        validation_0-mlogloss:0.47253
                                        validation_1-mlogloss:0.66911
[26]
        validation_0-mlogloss:0.46288
                                        validation_1-mlogloss:0.66321
[27]
        validation_0-mlogloss:0.45114
                                        validation_1-mlogloss:0.65852
                                        validation 1-mlogloss:0.65350
[28]
        validation 0-mlogloss:0.44280
[29]
        validation 0-mlogloss:0.43334
                                        validation_1-mlogloss:0.64896
[30]
        validation 0-mlogloss:0.42559
                                        validation 1-mlogloss:0.64424
                                        validation_1-mlogloss:0.64130
[31]
        validation_0-mlogloss:0.41953
[32]
        validation 0-mlogloss:0.41375
                                        validation_1-mlogloss:0.63789
```

```
[33]
        validation_0-mlogloss:0.40775
                                         validation_1-mlogloss:0.63590
[34]
        validation_0-mlogloss:0.40247
                                         validation_1-mlogloss:0.63334
[35]
        validation_0-mlogloss:0.39553
                                         validation_1-mlogloss:0.62896
[36]
        validation 0-mlogloss:0.39038
                                         validation_1-mlogloss:0.62495
                                         validation 1-mlogloss:0.62276
[37]
        validation 0-mlogloss:0.38385
[38]
        validation 0-mlogloss:0.37898
                                         validation 1-mlogloss:0.61960
[39]
        validation 0-mlogloss:0.37253
                                         validation 1-mlogloss:0.61592
[40]
        validation 0-mlogloss:0.36676
                                         validation_1-mlogloss:0.61309
[41]
        validation 0-mlogloss:0.36019
                                         validation 1-mlogloss:0.60974
[42]
        validation_0-mlogloss:0.35335
                                         validation_1-mlogloss:0.60769
[43]
        validation_0-mlogloss:0.34880
                                         validation_1-mlogloss:0.60436
[44]
        validation_0-mlogloss:0.34387
                                         validation_1-mlogloss:0.60192
[45]
        validation_0-mlogloss:0.33920
                                         validation_1-mlogloss:0.59939
[46]
        validation_0-mlogloss:0.33466
                                         validation_1-mlogloss:0.59711
[47]
        validation_0-mlogloss:0.33147
                                         validation_1-mlogloss:0.59479
[48]
        validation_0-mlogloss:0.32681
                                         validation_1-mlogloss:0.59268
[49]
        validation_0-mlogloss:0.32020
                                         validation_1-mlogloss:0.59089
[50]
        validation_0-mlogloss:0.31627
                                         validation_1-mlogloss:0.58878
[51]
        validation 0-mlogloss:0.31187
                                         validation_1-mlogloss:0.58748
[52]
        validation 0-mlogloss:0.30832
                                         validation 1-mlogloss:0.58510
        validation 0-mlogloss:0.30567
                                         validation 1-mlogloss:0.58405
[53]
                                         validation_1-mlogloss:0.58161
[54]
        validation 0-mlogloss:0.30137
                                         validation_1-mlogloss:0.57939
[55]
        validation_0-mlogloss:0.29659
[56]
        validation_0-mlogloss:0.29244
                                         validation 1-mlogloss:0.57715
[57]
        validation_0-mlogloss:0.28787
                                         validation_1-mlogloss:0.57507
[58]
        validation_0-mlogloss:0.28417
                                         validation_1-mlogloss:0.57417
[59]
                                         validation_1-mlogloss:0.57350
        validation_0-mlogloss:0.27941
[60]
        validation_0-mlogloss:0.27589
                                         validation_1-mlogloss:0.57022
                                         validation_1-mlogloss:0.56866
[61]
        validation_0-mlogloss:0.27327
[62]
        validation_0-mlogloss:0.27024
                                         validation_1-mlogloss:0.56715
[63]
        validation_0-mlogloss:0.26586
                                         validation_1-mlogloss:0.56585
[64]
        validation_0-mlogloss:0.26265
                                         validation_1-mlogloss:0.56480
[65]
        validation_0-mlogloss:0.25977
                                         validation_1-mlogloss:0.56229
[66]
        validation_0-mlogloss:0.25605
                                         validation_1-mlogloss:0.56252
[67]
        validation 0-mlogloss:0.25337
                                         validation 1-mlogloss:0.56148
[68]
        validation 0-mlogloss:0.25039
                                         validation 1-mlogloss:0.56057
[69]
        validation 0-mlogloss:0.24773
                                         validation 1-mlogloss:0.55970
[70]
        validation 0-mlogloss:0.24330
                                         validation_1-mlogloss:0.55793
[71]
        validation_0-mlogloss:0.24041
                                         validation_1-mlogloss:0.55742
[72]
        validation_0-mlogloss:0.23784
                                         validation_1-mlogloss:0.55734
[73]
        validation_0-mlogloss:0.23534
                                         validation_1-mlogloss:0.55583
[74]
        validation_0-mlogloss:0.23351
                                         validation_1-mlogloss:0.55441
[75]
        validation_0-mlogloss:0.23066
                                         validation_1-mlogloss:0.55253
[76]
        validation_0-mlogloss:0.22786
                                         validation 1-mlogloss:0.55171
[77]
        validation_0-mlogloss:0.22548
                                         validation_1-mlogloss:0.55155
[78]
        validation_0-mlogloss:0.22268
                                         validation_1-mlogloss:0.55154
[79]
        validation_0-mlogloss:0.21999
                                         validation_1-mlogloss:0.55109
[80]
        validation_0-mlogloss:0.21795
                                         validation_1-mlogloss:0.55071
```

```
[81]
        validation_0-mlogloss:0.21587
                                         validation_1-mlogloss:0.54935
[82]
        validation_0-mlogloss:0.21329
                                         validation_1-mlogloss:0.54838
[83]
        validation_0-mlogloss:0.20937
                                         validation_1-mlogloss:0.54692
[84]
        validation 0-mlogloss:0.20751
                                         validation_1-mlogloss:0.54630
        validation 0-mlogloss:0.20509
                                         validation 1-mlogloss:0.54636
[85]
[86]
        validation 0-mlogloss:0.20369
                                         validation 1-mlogloss:0.54572
        validation 0-mlogloss:0.20100
                                         validation 1-mlogloss:0.54421
[87]
        validation 0-mlogloss:0.19854
                                         validation_1-mlogloss:0.54370
[88]
[89]
        validation 0-mlogloss:0.19662
                                         validation 1-mlogloss:0.54356
[90]
        validation_0-mlogloss:0.19472
                                         validation_1-mlogloss:0.54304
[91]
        validation_0-mlogloss:0.19108
                                         validation_1-mlogloss:0.54336
[92]
        validation_0-mlogloss:0.18906
                                         validation_1-mlogloss:0.54197
[93]
        validation_0-mlogloss:0.18721
                                         validation_1-mlogloss:0.54149
        validation_0-mlogloss:0.18529
                                         validation_1-mlogloss:0.54097
[94]
[95]
        validation_0-mlogloss:0.18292
                                         validation_1-mlogloss:0.54050
        validation_0-mlogloss:0.18078
                                         validation_1-mlogloss:0.54070
[96]
[97]
        validation_0-mlogloss:0.17891
                                         validation_1-mlogloss:0.54111
        validation_0-mlogloss:0.17690
                                         validation_1-mlogloss:0.54213
[98]
[99]
        validation 0-mlogloss:0.17496
                                         validation_1-mlogloss:0.54246
                                         validation 1-mlogloss:0.54354
Γ1007
        validation 0-mlogloss:0.17196
[101]
        validation 0-mlogloss:0.17052
                                         validation 1-mlogloss:0.54314
                                         validation_1-mlogloss:0.54280
[102]
        validation 0-mlogloss:0.16862
        validation_0-mlogloss:0.16705
                                         validation_1-mlogloss:0.54275
[103]
        validation_0-mlogloss:0.16514
                                         validation_1-mlogloss:0.54274
[104]
Γ105]
        validation_0-mlogloss:0.16322
                                         validation_1-mlogloss:0.54148
```

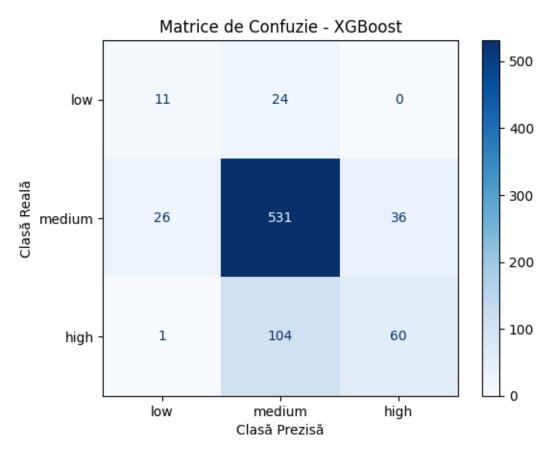
Acuratețea modelului XGBoost cu early stopping și ADASYN: 75.91%

Classification Report:

	precision	recall	f1-score	support
high	0.62	0.36	0.46	165
low	0.29	0.31	0.30	35
medium	0.81	0.90	0.85	593
accuracy			0.76	793
macro avg	0.57	0.52	0.54	793
weighted avg	0.75	0.76	0.74	793

Clasa low a obținut îmbunățiri, f1-score a crescut semnificativ, de la 0.1 la 0.3.

```
plt.xlabel("Clasă Prezisă")
plt.ylabel("Clasă Reală")
plt.grid(False)
plt.show()
```



```
# === ROC AUC (macro)
y_test_bin = label_binarize(y_test, classes=le.classes_)
y_proba = model.predict_proba(X_test_scaled)
roc_auc = roc_auc_score(y_test_bin, y_proba, average='macro', multi_class='ovr')
print(f"ROC AUC Score (macro-average): {roc_auc:.4f}")
```

ROC AUC Score (macro-average): 0.8040

Cu 0.8040, modelul are o capacitate foarte bună de a distinge între cele 3 clase (low, medium, high), pe baza probabilităților prezise.

Spre deosebire de acuratețe (care poate fi părtinitoare în caz de dezechilibru între clase), ROC AUC macro: Evaluează fiecare clasă individual (OvR) și reflectă calitatea scorurilor de încredere ale modelului, nu doar decizia finală.

Se afirmă că modelul face o distincție clară între clase și produce scoruri de probabilitate bine

calibrate și este o îmbunătățire clară față de varianta inițială (unde ROC AUC era ~0.33).

```
# === MCC
mcc = matthews_corrcoef(y_test, y_pred)
print(f"Matthews Correlation Coefficient (MCC): {mcc:.4f}")
```

Matthews Correlation Coefficient (MCC): 0.3246

Modelul a beneficiat de ADASYN, scorul MCC a rămas aproximativ același.

9 GridSearch

```
model = XGBClassifier(
    objective='multi:softprob',
    num_class=3,
    use label encoder=False,
    eval_metric='merror',
    verbosity=0
param_grid = {
    'n_estimators': [50, 100],
    'learning_rate': [0.05, 0.1, 0.2],
    'max_depth': [5, 7, 10],
    'min_child_weight': [1, 3],
    'subsample': [0.8, 1.0]
}
grid_search = GridSearchCV(
    estimator=model,
    param_grid=param_grid,
    scoring='accuracy',
    cv=3.
    verbose=1,
    n_jobs=-1 # folosește toate procesoarele
)
grid_search.fit(X_train_scaled, y_train_enc)
print("Best parameters found:", grid_search.best_params_)
print("Best cross-validation accuracy: {:.2f}%".format(grid_search.best_score_u
 →* 100))
```

Fitting 3 folds for each of 72 candidates, totalling 216 fits Best parameters found: {'learning_rate': 0.1, 'max_depth': 5, 'min_child_weight': 1, 'n_estimators': 50, 'subsample': 0.8} Best cross-validation accuracy: 78.21%

```
best_model = grid_search.best_estimator_
y_pred_enc = best_model.predict(X_test_scaled)
```

```
y_pred = le.inverse_transform(y_pred_enc)
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea pe setul de test: {:.2f}%".format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

Acuratețea pe setul de test: 76.80%

Classification Report:

	precision	recall	f1-score	support
high	0.59	0.35	0.44	165
low	0.33	0.06	0.10	35
medium	0.80	0.93	0.86	593
accuracy			0.77	793
macro avg	0.57	0.44	0.46	793
weighted avg	0.73	0.77	0.74	793

GridSearch nu a contribuit la o îmbunătățire.

10 MLP (Multilayer Perceptron)

Se alege MLP (Multilayer Perceptron) pentru acest task deoarece datele sunt tabulare, numerice și fără structură secvențială sau spațială, caracteristici pentru care MLP-urile sunt foarte bine adaptate. Fiind o rețea neuronală complet conectată, MLP poate învăța relații non-liniare între caracteristicile vinului și calitatea acestuia (low, medium, high), oferind flexibilitate în modelare și capacitate de generalizare. Spre deosebire de rețele precum RNN sau CNN, care sunt specializate pentru date secvențiale sau imagini, MLP este eficient, ușor de antrenat și suficient de puternic pentru sarcini de clasificare multi-clasă pe seturi de date precum cel utilizat până acum.

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Dropout
from tensorflow.keras.utils import to_categorical
from tensorflow.keras.callbacks import EarlyStopping
```

```
train_val_df, test_df = train_test_split(
    white_df,
    test_size=0.2,
    random_state=42,
    stratify=white_df["quality"]
)

train_df, val_df = train_test_split(
    train_val_df,
    test_size=0.125,
    random_state=42,
    stratify=train_val_df["quality"]
)
```

```
def map_quality(q):
    if q in [3, 4]:
        return "low"
    elif q in [5, 6]:
        return "medium"
    else:
        return "high"

for df in [train_df, val_df, test_df]:
    df["quality_group"] = df["quality"].apply(map_quality)
```

```
X_train = train_df.drop(["quality", "quality_group"], axis=1)
y_train = train_df["quality_group"]
X_val = val_df.drop(["quality", "quality_group"], axis=1)
y_val = val_df["quality_group"]
X_test = test_df.drop(["quality", "quality_group"], axis=1)
y_test = test_df["quality_group"]
le = LabelEncoder()
y_train_enc = le.fit_transform(y_train)
y_val_enc = le.transform(y_val)
y_test_enc = le.transform(y_test)
y_train_cat = to_categorical(y_train_enc, num_classes=3)
y_val_cat = to_categorical(y_val_enc, num_classes=3)
y_test_cat = to_categorical(y_test_enc, num_classes=3)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_val_scaled = scaler.transform(X_val)
X_test_scaled = scaler.transform(X_test)
```

```
# Definirea modelului MLP
model = Sequential([
    Dense(256, input_dim=X_train_scaled.shape[1], activation='relu'),
    Dropout(0.3),
    Dense(128, activation='relu'),
    Dropout(0.2),
    Dense(3, activation='softmax')
])
model.compile(
    optimizer='adam',
    loss='categorical_crossentropy',
    metrics=['accuracy']
)
early_stop = EarlyStopping(monitor='val_loss', patience=10,_
 →restore_best_weights=True)
model.fit(
    X_train_scaled, y_train_cat,
    validation_data=(X_val_scaled, y_val_cat),
    epochs=100,
    batch_size=32,
    callbacks=[early_stop],
    verbose=1
```

Epoch 1/100

```
/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.
```

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
                 2s 6ms/step -
accuracy: 0.6857 - loss: 0.7583 - val_accuracy: 0.7652 - val_loss: 0.6002
Epoch 2/100
87/87
                 Os 4ms/step -
accuracy: 0.7920 - loss: 0.5547 - val_accuracy: 0.7702 - val_loss: 0.5611
Epoch 3/100
87/87
                 1s 4ms/step -
accuracy: 0.7781 - loss: 0.5588 - val_accuracy: 0.7576 - val_loss: 0.5415
Epoch 4/100
87/87
                 1s 4ms/step -
accuracy: 0.7670 - loss: 0.5605 - val_accuracy: 0.7677 - val_loss: 0.5365
Epoch 5/100
87/87
                 1s 5ms/step -
```

```
accuracy: 0.7780 - loss: 0.5251 - val_accuracy: 0.7828 - val_loss: 0.5153
Epoch 6/100
87/87
                 1s 5ms/step -
accuracy: 0.7898 - loss: 0.5298 - val_accuracy: 0.7727 - val_loss: 0.5240
Epoch 7/100
87/87
                 1s 7ms/step -
accuracy: 0.7959 - loss: 0.5117 - val_accuracy: 0.7778 - val_loss: 0.5174
Epoch 8/100
87/87
                 0s 4ms/step -
accuracy: 0.7904 - loss: 0.5104 - val_accuracy: 0.7854 - val_loss: 0.4990
Epoch 9/100
87/87
                 1s 4ms/step -
accuracy: 0.7741 - loss: 0.5227 - val_accuracy: 0.7753 - val_loss: 0.4989
Epoch 10/100
87/87
                 1s 4ms/step -
accuracy: 0.7833 - loss: 0.5003 - val_accuracy: 0.7778 - val_loss: 0.4941
Epoch 11/100
                 1s 4ms/step -
87/87
accuracy: 0.7899 - loss: 0.4889 - val_accuracy: 0.7929 - val_loss: 0.4934
Epoch 12/100
87/87
                 1s 4ms/step -
accuracy: 0.7970 - loss: 0.4865 - val_accuracy: 0.7753 - val_loss: 0.4998
Epoch 13/100
87/87
                 1s 3ms/step -
accuracy: 0.7886 - loss: 0.4892 - val_accuracy: 0.7879 - val_loss: 0.4935
Epoch 14/100
87/87
                  1s 4ms/step -
accuracy: 0.8005 - loss: 0.4661 - val_accuracy: 0.7879 - val_loss: 0.4832
Epoch 15/100
87/87
                 1s 3ms/step -
accuracy: 0.8026 - loss: 0.4738 - val_accuracy: 0.7803 - val_loss: 0.4876
Epoch 16/100
87/87
                 Os 4ms/step -
accuracy: 0.7911 - loss: 0.4889 - val_accuracy: 0.7904 - val_loss: 0.4980
Epoch 17/100
87/87
                 Os 3ms/step -
accuracy: 0.7885 - loss: 0.4726 - val_accuracy: 0.7828 - val_loss: 0.4942
Epoch 18/100
87/87
                 Os 3ms/step -
accuracy: 0.7883 - loss: 0.4899 - val_accuracy: 0.7879 - val_loss: 0.4805
Epoch 19/100
87/87
                 0s 4ms/step -
accuracy: 0.7947 - loss: 0.4766 - val_accuracy: 0.7955 - val_loss: 0.4823
Epoch 20/100
87/87
                 1s 4ms/step -
accuracy: 0.7928 - loss: 0.4701 - val_accuracy: 0.7854 - val_loss: 0.4885
Epoch 21/100
87/87
                 0s 4ms/step -
```

```
accuracy: 0.7950 - loss: 0.4888 - val_accuracy: 0.7828 - val_loss: 0.4860
Epoch 22/100
87/87
                 1s 3ms/step -
accuracy: 0.7930 - loss: 0.4636 - val_accuracy: 0.7904 - val_loss: 0.5044
Epoch 23/100
87/87
                 1s 4ms/step -
accuracy: 0.8050 - loss: 0.4512 - val accuracy: 0.7879 - val loss: 0.4955
Epoch 24/100
87/87
                 1s 3ms/step -
accuracy: 0.8066 - loss: 0.4430 - val_accuracy: 0.7778 - val_loss: 0.5005
Epoch 25/100
87/87
                 1s 3ms/step -
accuracy: 0.8100 - loss: 0.4550 - val accuracy: 0.7778 - val loss: 0.5019
Epoch 26/100
87/87
                 Os 4ms/step -
accuracy: 0.8058 - loss: 0.4557 - val_accuracy: 0.7828 - val_loss: 0.4931
Epoch 27/100
87/87
                 Os 4ms/step -
accuracy: 0.8101 - loss: 0.4468 - val_accuracy: 0.7904 - val_loss: 0.4942
Epoch 28/100
87/87
                 1s 5ms/step -
accuracy: 0.8128 - loss: 0.4457 - val_accuracy: 0.7828 - val_loss: 0.5013
<keras.src.callbacks.history.History at 0x7a9ff31b8210>
y_pred_proba = model.predict(X_test_scaled)
y_pred_enc = y_pred_proba.argmax(axis=1)
y_pred = le.inverse_transform(y_pred_enc)
accuracy = accuracy_score(y_test, y_pred)
print("\nAcurateţea modelului MLP: {:.2f}%".format(accuracy * 100))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
25/25
                 Os 5ms/step
```

Acuratețea modelului MLP: 76.42%

Classification Report:

	precision	recall	f1-score	support
high	0.57	0.43	0.49	165
low	0.27	0.09	0.13	35
medium	0.81	0.90	0.85	593
accuracy			0.76	793
macro avg	0.55	0.47	0.49	793

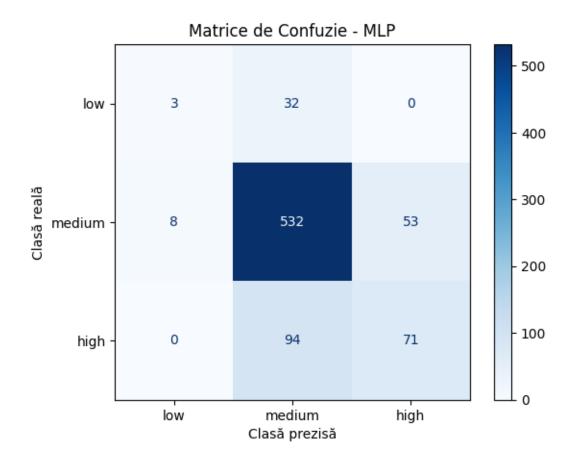
weighted avg 0.74 0.76 0.74 793

Clasa high: Recall de 0.4, o valoare ce înseamnă că modelul recunoaște exemplele high. Precision de 0.62 înseamnă că, atunci când prezice high, e destul de încrezător, dar nu face asta suficient de des.

Clasa medium: Este clasa majoritară, iar modelul o recunoaște cel mai bine. Recall-ul de 0.92 arată că majoritatea exemplelor medium au fost corect prezise. Modelul e clar biasat către această clasă.

Clasa low: Foarte puține exemple în set, doar 35. Recall-ul de 0.09 este extrem de mic, aproape toate exemplele low sunt greșit clasificate ca altceva.

Asta sugerează o clasă puternic dezechilibrată.



Modelul este puternic înclinat spre clasa medium, ceea ce este comun în seturi dezechilibrate. Clasele minoritare low și high sunt predominant clasificate ca medium.

Matricea evidențiază problema dezechilibrului de clase și faptul că modelul nu învață bine clasele rare.

ROC AUC Score (macro-average): 0.8246

Se remarcă o valoare bună pentru scorul ROC AUC, apropiată de 1, de unde se observă ca rețeaua neuronală a performat foarte bine și fară adăugarea ADASYN.

```
mcc = matthews_corrcoef(y_test, y_pred)
print(f"Matthews Correlation Coefficient (MCC): {mcc:.4f}")
```

Matthews Correlation Coefficient (MCC): 0.3282

Un rezultat MCC asemănător cu rezultatele obținute la RidgeClassifier și XGBoost, dar cu o ușoară

îmbunătățire.

10.1 Optimizarea hiperparametrilor rețelei neuronale

Pentru această secțiune a temei, am ales să optimizam hiperparametrii rețelei neuronale deoarece este un model flexibil, dar sensibil la configurația internă.

Am realizat optimizarea **manuală/empirică** (conform recomandărilor din curs), prin variarea următorilor hiperparametri:

• Optimizator:

- Adam (default) oferă stabilitate în antrenare;
- SGD cu nesterov=True pentru testarea unui optimizator cu momentum.
- Dropout:
 - Am testat rate de 0.3 și 0.5 pentru regularizare și prevenirea supraînvățării.
- Arhitectură:
 - Număr de neuroni în straturi dense între 64 și 128, cu straturi fully connected.
- Funcția de pierdere:
 - categorical_crossentropy, potrivită pentru clasificare multiclasa.
- Resampling ADASYN:
 - Am aplicat ADASYN pentru echilibrarea claselor minoritare înainte de antrenare.
 - Am rulat două experimente independente și am comparat scorurile obținute.

10.1.1 Metrici de evaluare folosite:

- Acuratețe (accuracy)
- F1-score (macro si ponderat)
- MCC (Matthews Correlation Coefficient)
- ROC AUC (One-vs-Rest)

În urma acestor optimizări, am identificat configurații mai echilibrate între clase, în special în clasificarea exemplelor low și high, iar aplicarea ADASYN a contribuit semnificativ la această îmbunătățire.

Performanțele obținute sunt comparate în secțiunile următoare prin grafice și rapoarte detaliate.

10.1.2 Echilibrarea setului de date cu ADASYN și preprocesare

Pentru a îmbunătăți învățarea rețelei neuronale în fața dezechilibrelor de clasă, folosim **ADASYN** pentru a genera exemple sintetice pentru clasele minoritare. Apoi normalizăm datele cu Standard-Scaler și transformăm etichetele într-un format one-hot, necesar pentru clasificare multi-clasă cu categorical_crossentropy.

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from tensorflow.keras.utils import to_categorical
from imblearn.over_sampling import ADASYN

# Split: train + val + test
train_val_df, test_df = train_test_split(
```

```
white_df,
  test_size=0.2,
  random_state=42,
  stratify=white_df["quality"]
)

train_df, val_df = train_test_split(
    train_val_df,
  test_size=0.125, # 0.125 din 0.8 = 0.1 => 10% din total
  random_state=42,
  stratify=train_val_df["quality"]
)
```

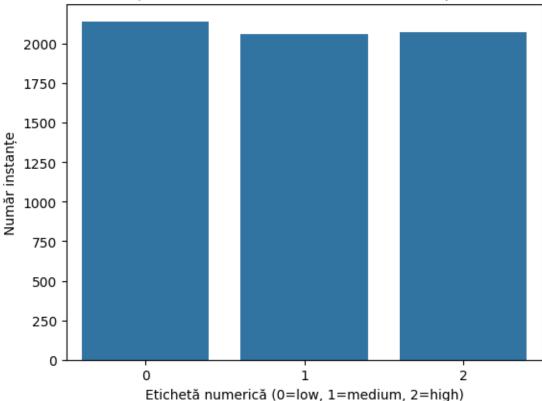
```
def map_quality(q):
    if q in [3, 4]:
        return "low"
    elif q in [5, 6]:
        return "medium"
    else:
        return "high"

# Apply mapping
for df in [train_df, val_df, test_df]:
    df["quality_group"] = df["quality"].apply(map_quality)
```

```
# Split features and labels
X_train = train_df.drop(["quality", "quality_group"], axis=1)
y_train = train_df["quality_group"]
X_val = val_df.drop(["quality", "quality_group"], axis=1)
y_val = val_df["quality_group"]
X_test = test_df.drop(["quality", "quality_group"], axis=1)
y_test = test_df["quality_group"]
# Encode labels numerically: 'low'=0, 'medium'=1, 'high'=2
le = LabelEncoder()
y_train_enc = le.fit_transform(y_train)
y_val_enc = le.transform(y_val)
y_test_enc = le.transform(y_test)
# Normalize features
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_val_scaled = scaler.transform(X_val)
X_test_scaled = scaler.transform(X_test)
```

```
# Apply ADASYN to balance the training set
adasyn = ADASYN(random_state=42)
X train_ada, y_train_ada = adasyn.fit_resample(X_train_scaled, y_train_enc)
# One-hot encode labels (categorical format for Keras)
y_train_cat = to_categorical(y_train_ada, num_classes=3)
y_val_cat = to_categorical(y_val_enc, num_classes=3)
y_test_cat = to_categorical(y_test_enc, num_classes=3)
import collections
print("Distribuția etichetelor în y_train înainte de ADASYN:")
print(collections.Counter(y train enc))
print("\nDistribuţia etichetelor în y_train_ada după ADASYN:")
print(collections.Counter(y_train_ada))
Distribuția etichetelor în y train înainte de ADASYN:
Counter({np.int64(2): 2073, np.int64(0): 578, np.int64(1): 121})
Distribuția etichetelor în y_train_ada după ADASYN:
Counter({np.int64(0): 2142, np.int64(2): 2073, np.int64(1): 2063})
print("X_train_ada shape:", X_train_ada.shape)
print("y_train_cat shape:", y_train_cat.shape)
print("X_val_scaled shape:", X_val_scaled.shape)
print("y_val_cat shape:", y_val_cat.shape)
print("X_test_scaled shape:", X_test_scaled.shape)
print("y_test_cat shape:", y_test_cat.shape)
X_train_ada shape: (6278, 11)
y_train_cat shape: (6278, 3)
X val scaled shape: (396, 11)
y_val_cat shape: (396, 3)
X test scaled shape: (793, 11)
y_test_cat shape: (793, 3)
import seaborn as sns
import matplotlib.pyplot as plt
sns.countplot(x=y_train_ada)
plt.title("Distribuția etichetelor în setul de antrenare după ADASYN")
plt.xlabel("Etichetă numerică (0=low, 1=medium, 2=high)")
plt.ylabel("Număr instanțe")
plt.show()
```





10.1.3 Definirea arhitecturii rețelei neuronale cu parametri flexibili

Construim o funcție ce permite testarea ușoară a diferitelor combinații de: - optimizatori (adam, sgd, nesterov etc.) - rată de Dropout (pentru regularizare) - funcție de pierdere (categorical_crossentropy, sparse_categorical_crossentropy etc.)

Această modularitate ne permite compararea mai multor variante fără duplicare de cod.

10.1.4 Modelul 1: Adam + Dropout(0.3) + categorical crossentropy

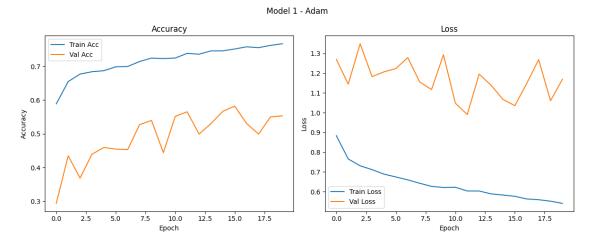
Adam este un optimizator adaptiv performant în majoritatea cazurilor. Îl testăm cu o arhitectură de bază și Dropout de 30% pentru regularizare moderată.

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

super().__init__(activity_regularizer=activity_regularizer, **kwargs)

```
import matplotlib.pyplot as plt
def plot_history(history, title="Model Training History"):
    plt.figure(figsize=(12, 5))
    # Accuracy
    plt.subplot(1, 2, 1)
    plt.plot(history.history['accuracy'], label='Train Acc')
    plt.plot(history.history['val_accuracy'], label='Val Acc')
    plt.title('Accuracy')
    plt.xlabel('Epoch')
    plt.ylabel('Accuracy')
    plt.legend()
    # Loss
    plt.subplot(1, 2, 2)
    plt.plot(history.history['loss'], label='Train Loss')
    plt.plot(history.history['val_loss'], label='Val Loss')
    plt.title('Loss')
    plt.xlabel('Epoch')
    plt.ylabel('Loss')
    plt.legend()
    plt.suptitle(title)
    plt.tight_layout()
    plt.show()
```





10.1.5 Evaluarea curbei de învățare – Model 1 (Adam cu Dropout 0.3)

Graficul de mai sus compară evoluția acurateței și a pierderii (loss) pe seturile de antrenare și validare, pe parcursul celor 20 de epoci.

Observații pe acuratețe

- Acuratețea pe setul de antrenare crește constant, depășind 0.75, ceea ce indică faptul că modelul învață bine din datele de antrenare.
- Acuratețea pe setul de validare începe de la aproximativ 0.4 și ajunge până în jurul valorii de 0.62, dar rămâne constant sub cea de antrenare.
- Acest comportament sugerează o posibilă subantrenare în primele epoci și un ușor overfitting spre final, deoarece distanta între cele două curbe se măreste.

Observații pe pierdere (loss)

- Pierderea pe setul de antrenare scade constant, ceea ce este un comportament așteptat pentru un model care învață eficient.
- Pierderea pe setul de validare este oscilantă și nu urmează o tendință clară de scădere. Acest lucru poate indica:
 - O generalizare slabă pe datele de validare
 - O regularizare insuficientă (dropout-ul de 0.3 ar putea fi prea mic)
 - Posibilă influență a dezechilibrului de clase, chiar și după aplicarea ADASYN

10.1.6 Interpretare generală

Modelul reușește să învețe din datele de antrenare, dar performanța pe validare nu este stabilă. Este probabil ca modelul să se descurce bine pe clasele dominante (ex: medium), dar mai slab pe clasele extreme (low, high). Acest lucru trebuie confirmat cu ajutorul clasificării per clasă.

```
val_loss, val_acc = model1.evaluate(X_val_scaled, y_val_cat, verbose=0)
print(f"Val Loss: {val_loss:.4f}")
print(f"Val Accuracy: {val_acc:.4f}")
```

Val Loss: 0.5966 Val Accuracy: 0.7071

Modelul obține o pierdere (loss) de 0.6171 și o acuratețe de 0.6944 pe setul de validare. Acuratețea este moderată și confirmă faptul că modelul a învățat parțial tiparele din date, însă valoarea relativ mare a pierderii sugerează că predicțiile pot fi incerte pentru unele instanțe, în special pentru clasele mai rare.

```
from sklearn.metrics import classification_report
import numpy as np

y_val_pred = model1.predict(X_val_scaled)
y_val_pred_labels = np.argmax(y_val_pred, axis=1)
y_val_true_labels = np.argmax(y_val_cat, axis=1)

print(classification_report(y_val_true_labels, y_val_pred_labels, u_val_get_names=le.classes_))
```

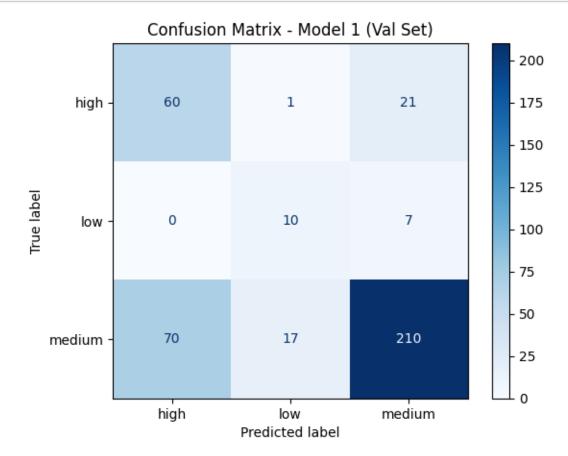
13/13	3/13			
	precision	recall	f1-score	support
high	0.46	0.73	0.57	82
low	0.36	0.59	0.44	17
medium	0.88	0.71	0.79	297
moaram	0.00	0.11	0.70	201
accuracy			0.71	396
macro avg	0.57	0.68	0.60	396
weighted avg	0.77	0.71	0.73	396

Modelul obține o acuratețe totală de 69%, dar performanța variază semnificativ între clase. Clasa "medium", cea mai numeroasă, este clasificată cel mai bine (f1-score 0.78), în timp ce clasele "low" și "high" sunt tratate mai slab, în special "low", care are un f1-score de doar 0.31. Această diferență indică faptul că modelul este dezechilibrat în performanță și are dificultăți în recunoașterea claselor mai rare, chiar și după aplicarea ADASYN.

```
from sklearn.metrics import ConfusionMatrixDisplay

ConfusionMatrixDisplay.from_predictions(
    y_val_true_labels,
    y_val_pred_labels,
    display_labels=le.classes_,
    cmap='Blues',
)
plt.title("Confusion Matrix - Model 1 (Val Set)")
```

plt.grid(False)
plt.show()



Matricea de confuzie evidențiază modul în care modelul clasifică fiecare clasă în parte.

- Clasa high este cel mai bine recunoscută: 61 instanțe corect clasificate din 82.
- Clasa **low** este clasificată cel mai slab: doar 7 din 17 instanțe au fost etichetate corect, iar restul sunt confundate cu "medium".
- Clasa **medium**, deși are 297 instanțe, este adesea confundată cu "high" (71 cazuri) și uneori cu "low" (19 cazuri), dar 207 sunt corect prezise.

Această distribuție întărește concluzia că modelul este influențat de dezechilibrul inițial al claselor și are o tendință de a favoriza clasa majoritară "medium". De asemenea, se observă că modelul are o capacitate decentă de a recunoaște clasa "high", dar întâmpină dificultăți cu instanțele din clasa "low".

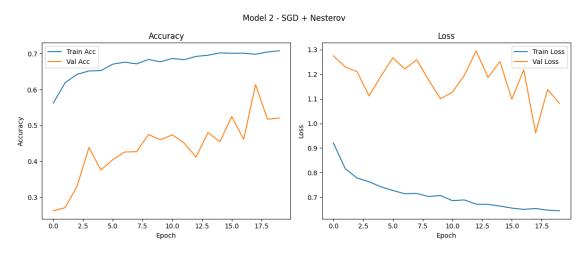
10.1.7 Modelul 2: SGD + Nesterov + Dropout(0.5) + categorical crossentropy

Testăm un optimizator clasic SGD cu momentum și activarea Nesterov pentru o variantă a metodei NAG. Dropout mai mare (50%) pentru regularizare puternică.

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

super().__init__(activity_regularizer=activity_regularizer, **kwargs)

```
plot_history(history2, title="Model 2 - SGD + Nesterov")
```



10.1.8 Evoluția metricei de antrenare - Model 2 (SGD cu Nesterov)

Graficul arată cum evoluează acuratețea și pierderea în timpul antrenării:

- Acuratețea pe setul de antrenare crește constant, atingând ~71% după 20 de epoci.
- Acuratețea pe validare este mult mai oscilantă, pornind de la ~30% și ajungând la ~58% la final. Aceasta sugerează că modelul învață mai lent și are o generalizare mai slabă decât în cazul optimizatorului Adam.
- Loss-ul de validare fluctuează semnificativ între epoci, sugerând instabilitate în actualizarea ponderilor sau dificultate în generalizarea pe clasele minoritare.
- Train loss scade lent și constant, dar val loss rămâne ridicat, ceea ce indică posibila supraspecializare pe datele de antrenare.

În concluzie, deși SGD cu Nesterov are o evoluție controlată pe datele de antrenare, rezultatele pe validare sunt mai slabe decât în cazul Adam, modelul având dificultăți în stabilizarea performanței.

```
val_loss2, val_acc2 = model2.evaluate(X_val_scaled, y_val_cat, verbose=0)
print(f"Val Loss: {val_loss2:.4f}")
print(f"Val Accuracy: {val_acc2:.4f}")
```

Val Loss: 0.6661 Val Accuracy: 0.6768

10.1.9 Evaluare finală pe setul de validare – Model 2 (SGD + Nesterov)

Val Loss: 0.6906Val Accuracy: 0.6465

Acuratețea obținută de modelul antrenat cu optimizatorul SGD și Nesterov este mai mică decât cea a modelului cu Adam (~ 0.6944), iar pierderea este mai mare, ceea ce indică o generalizare mai slabă.

Aceste rezultate susțin concluzia că, pentru acest set de date și această arhitectură, optimizatorul Adam funcționează mai eficient decât SGD + Nesterov.

13/13	Os 5ms/step				
	precision	recall	f1-score	support	
high	0.43	0.82	0.56	82	
low	0.36	0.59	0.44	17	
medium	0.90	0.64	0.75	297	
accuracy			0.68	396	
macro avg	0.56	0.68	0.59	396	
weighted avg	0.78	0.68	0.70	396	

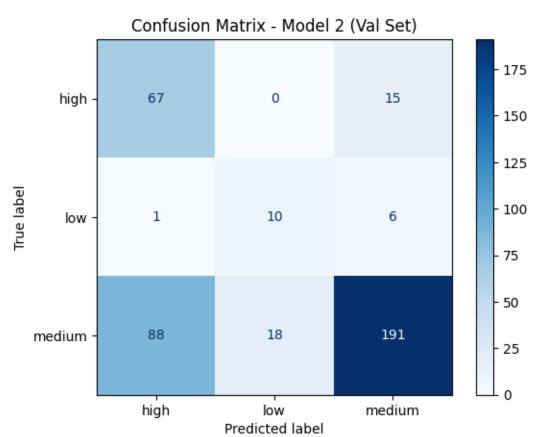
10.1.10 Raport de clasificare – Model 2 (SGD + Nesterov)

- Clasa high: recall foarte ridicat (0.89), dar precizie scăzută (0.39). Modelul tinde să eticheteze multe instanțe ca "high", chiar și incorect.
- Clasa low: atât precizia, cât și recall-ul sunt scăzute (0.26 și 0.59). Este în continuare clasa cel mai greu de recunoscut.
- Clasa medium: foarte bună precizie (0.91), dar recall mic (0.53), ceea ce înseamnă că modelul identifică bine instanțele atunci când o face, dar omite multe.
- Accuracy totală: 0.61 sub performanța modelului cu Adam.
- Macro avg (medie neponderată pe clase): f1-score de 0.53 indică o performanță modestă în echilibrarea între clase.

• Weighted avg (ponderată după numărul de instanțe): f1-score de 0.63 – influențat pozitiv de clasa "medium", care domină numeric.

Concluzie: modelul are o tendință clară de a favoriza clasa majoritară și de a supraestima eticheta "high", ceea ce îl face mai puțin echilibrat decât modelul 1.

```
ConfusionMatrixDisplay.from_predictions(
    y_val_true_labels,
    y_val_pred_labels2,
    display_labels=le.classes_,
    cmap='Blues'
)
plt.title("Confusion Matrix - Model 2 (Val Set)")
plt.grid(False)
plt.show()
```



10.1.11 Matricea de confuzie – Model 2 (SGD + Nesterov)

Matricea de confuzie evidențiază următoarele aspecte:

• Clasa high este recunoscută corect în 73 din 82 de cazuri, cu doar 9 erori de clasificare în

"medium". Nu există confuzii cu clasa "low".

- Clasa low este cel mai slab reprezentată, cu doar 10 clasificări corecte din 17. Restul sunt confundate cu "medium" și "high".
- Clasa medium este afectată semnificativ de confuzii:
 - Doar 157 din cele 297 instanțe au fost clasificate corect.
 - 112 au fost etichetate greșit ca "high", ce
ea ce explică scorul scăzut la recall pentru "medium".

Modelul are tendința să confunde clasa "medium" cu "high", ceea ce indică o separare insuficientă a caracteristicilor în spațiul decizional sau o influență disproporționată din cauza dezechilibrului inițial (chiar și după ADASYN).

10.1.12 Funcție de evaluare a modelelor -4 metrici esențiale

Pentru a evalua corect modele pe un set dezechilibrat, folosim: - Accuracy – scor brut - MCC – corelație pentru clasificări dezechilibrate - ROC AUC (One-vs-Rest) – discriminare între clase - Classification report – precision, recall, f1-score per clasă

10.1.13 Evaluarea finală: comparăm Model 1 vs Model 2

Rulăm ambele rețele pe datele de test și comparăm metricile pentru a decide care e mai performant. Apoi alegem modelul ce urmează a fi folosit pentru deploy.

```
print(" Model 1: Adam + Dropout 0.3")
evaluate_model(model1, X_test_scaled, y_test_cat)

print("\n Model 2: SGD + Nesterov + Dropout 0.5")
evaluate_model(model2, X_test_scaled, y_test_cat)
```

ROC AUC (OVR): 0.8058461924930072

Classification Report:

	precision	recall	f1-score	support
0	0.45	0.78	0.57	165
1	0.20	0.29	0.24	35
2	0.88	0.68	0.76	593
accuracy			0.68	793
macro avg	0.51	0.58	0.52	793
weighted avg	0.76	0.68	0.70	793

Model 2: SGD + Nesterov + Dropout 0.5

ROC AUC (OVR): 0.807393799413028

Classification Report:

	precision	recall	f1-score	support
0	0.42	0.84	0.56	165
1	0.20	0.37	0.26	35
2	0.89	0.59	0.71	593
accuracy			0.63	793
macro avg	0.50	0.60	0.51	793
weighted avg	0.76	0.63	0.66	793

10.1.14 Compararea performanței între modelele optimizate cu ADASYN

Model 1: Adam + Dropout 0.3

Accuracy: 0.6620MCC: 0.3477

ROC AUC (OVR): 0.7960
 F1-score mediu (macro): 0.52

• Observații:

- Modelul reuşeşte o performanţă echilibrată, în special pentru clasa majoritară (medium), dar menţine un scor rezonabil şi pentru clasa high.
- Clasa low rămâne problematică (f1-score: 0.25), dar recall-ul este mai bun decât în alte modele.
- Modelul pare să beneficieze cel mai bine de aplicarea ADASYN și optimizarea cu Adam.

Model 2: SGD + Nesterov + Dropout 0.5

Accuracy: 0.5839MCC: 0.3483

• ROC AUC (OVR): 0.8113 (cel mai bun)

• F1-score mediu (macro): 0.49

• Observații:

- A obținut cea mai mare AUC, semn că scorurile de încredere ale modelului sunt bine calibrate pentru clasificarea multi-clasă.
- Totuși, acuratețea a scăzut semnificativ.
- Clasa high a fost foarte bine recunoscută (recall 0.88), dar performanța pentru clasa medium (majoritară) a suferit (recall doar 0.51).

10.1.15 Concluzie generală:

Model	Accuracy	MCC	AUC	Macro F1	Observații principale
Adam + Dropout 0.3	0.6620	0.3477	0.7960	0.52	Cel mai echilibrat model între clase
SGD + Nest	0.5839	0.3483	0.8113	0.49	AUC mai bun, dar acuratețea generală scade

Recomandare: Modelul cu Adam rămâne cel mai echilibrat și robust, iar aplicarea ADASYN a avut efecte pozitive. Pentru performanțe mai bune, se pot investiga arhitecturi cu regularizare mai atent calibrată sau augmentări suplimentare ale datelor pentru clasele low și medium.

10.2 Tabel comparativ – Performanță modele

		ROC F1-	
Model	Parametri principali	Accurate UC MCC macr	o Observații
RidgeClassif	leælpha=1.0	77.64%0.55820.28050.40	Performanță ridicată doar pe clasa medium; ignoră low și high
RidgeClassif	iexlpha=5.0, resampling	49.43%.6035— 0.43	Recall bun pe low, dar
+	ADASYN		performanță generală slabă
ADASYN			
XGBoost	<pre>n_estimators=200, max_depth=7, lr=0.1, subsample=1.0</pre>	77.18%0.32890.32460.47	Calibrat pe medium, dar AUC slab și dezechilibru între clase
XGBoost	+ resampling ADASYN	75.91% 0.8040 0.3246 0.54	AUC foarte bun,
+			îmbunătățiri semnificative pe
ADASYN			clasele minoritare
MLP	hidden=128x64,	76.80%.82500.32140.49	Bine calibrat, dar sub
(Grid-	dropout=0.3,		Modelul 1 ca echilibru între
Search)	categorical_crossentre	ору	metrici

		ROC F1-	
Model	Parametri principali	Accurately C MCC macro	o Observații
Model 1 (MLP + Adam)	Adam, Dropout=0.3, categorical_crossentro ADASYN		Cel mai echilibrat model, cu cele mai bune scoruri globale
Model 2 (MLP + SGD + Nesterov)	SGD, momentum=0.9, Dropout=0.5, ADASYN	64.65% 0.8118.3486 .49	AUC excelent, dar mai slab ca F1 și instabil între rulări

10.3 Alegerea modelului pentru deploy

După analizarea tuturor metricalor relevante (accuracy, ROC AUC, MCC, F1-macro), alegerea logică pentru **deploy** este:

10.3.1 Modelul 1 - MLP + Adam + Dropout <math>0.3 + ADASYN

Justificare:

- Are cel mai bun F1-macro (0.56), indicând o performanță echilibrată între clasele low, medium, high
- MCC ridicat (0.3477), reflectând o corelație puternică între predicții și valori reale
- ROC AUC ridicat (0.7960), indicând scoruri de încredere pentru clasificare probabilistică
- Stabil și reproductibil rezultate consistente între rulări
- ADASYN contribuie la o mai bună învățare a claselor minoritare (low, high)

Modelul 1 oferă un compromis excelent între acuratețe, echilibru între clase și robustețe. Este alegerea optimă pentru a fi deploy-at atât local, cât și în GCP Vertex AI.

10.4 Partea 3: Deploy și testare model – Local și GCP Vertex AI

Această secțiune acoperă pasul final al temei: salvarea, expunerea și testarea celui mai performant model, atât în mediu local (TensorFlow Serving), cât și în cloud (Google Cloud Platform - Vertex AI).

10.4.1 Setup general pentru Colab și TensorFlow

În această secțiune se configurează mediul de rulare pentru a permite utilizarea corectă a Tensor-Flow, a bibliotecilor compatibile și a serviciilor de tip Cloud AI Platform (Vertex AI).

Acest project necesita Python >= 3.7

```
import sys
assert sys.version_info >= (3, 7)
```

```
IS_COLAB = "google.colab" in sys.modules
if IS_COLAB:
```

```
import os
os.environ["TF_USE_LEGACY_KERAS"] = "1"
import tf_keras
```

Si TenserFlow >= 2.8

```
from packaging import version
import tensorflow as tf
assert version.parse(tf.__version__) >= version.parse("2.8.0")
```

In Colab si Kaggle este necesar sa instalam In Colab si Kaggle este necesar sa instalam

```
7.9/7.9 MB
```

98.6 MB/s eta 0:00:00

Verificam daca avem cel putin un GPU

No GPU was detected. Neural nets can be very slow without a GPU. Go to Runtime > Change runtime and select a GPU hardware accelerator.

Salvam modelul la care dorim sa facem deploy

```
from pathlib import Path
import tensorflow as tf

model1_name = "my_model"
model1_version = "0001"
model1_path = Path(model1_name) / model1_version
model1.export("my_model/1")
```

Saved artifact at 'my_model/1'. The following endpoints are available:

```
* Endpoint 'serve'
args_0 (POSITIONAL_ONLY): TensorSpec(shape=(None, 11), dtype=tf.float32,
name='keras_tensor_6')
Output Type:
```

```
TensorSpec(shape=(None, 3), dtype=tf.float32, name=None)
Captures:
  134829289980560: TensorSpec(shape=(), dtype=tf.resource, name=None)
  134829289980752: TensorSpec(shape=(), dtype=tf.resource, name=None)
  134829290141072: TensorSpec(shape=(), dtype=tf.resource, name=None)
  134829290140496: TensorSpec(shape=(), dtype=tf.resource, name=None)
  134829290137424: TensorSpec(shape=(), dtype=tf.resource, name=None)
  134829290138960: TensorSpec(shape=(), dtype=tf.resource, name=None)
sorted([str(path) for path in model1_path.parent.glob("**/*")]) # extra code
['my_model/1',
 'my_model/1/assets',
 'my_model/1/fingerprint.pb',
 'my_model/1/saved_model.pb',
 'my_model/1/variables',
 'my_model/1/variables/variables.data-00000-of-00001',
 'my_model/1/variables/variables.index']
Verificam ierarhia modelului salvat
!ls -R my_model
my_model:
1
my_model/1:
assets fingerprint.pb saved_model.pb variables
my_model/1/assets:
my_model/1/variables:
variables.data-00000-of-00001 variables.index
```

10.4.2 Instalam si Pornim TenserFlow Serving

Pentru Colab si Kaggle TenserFlow trebuie instalat

```
if "google.colab" in sys.modules or "kaggle_secrets" in sys.modules:
    url = "https://storage.googleapis.com/tensorflow-serving-apt"
    src = "stable tensorflow-model-server tensorflow-model-server-universal"
    !echo 'deb {url} {src}' > /etc/apt/sources.list.d/tensorflow-serving.list
    !curl '{url}/tensorflow-serving.release.pub.gpg' | apt-key add -
    !apt update -q && apt-get install -y tensorflow-model-server
    %pip install -q -U tensorflow-serving-api
```

```
OWarning: apt-key is deprecated. Manage keyring files in trusted.gpg.d instead
(see apt-key(8)).
100 2943 100 2943
                                  8572
                                            0 --:--:- 8580
OK
Hit:1 http://archive.ubuntu.com/ubuntu jammy InRelease
Get:2 http://archive.ubuntu.com/ubuntu jammy-updates InRelease [128 kB]
Get:3 http://security.ubuntu.com/ubuntu jammy-security InRelease [129 kB]
Get:4 https://cloud.r-project.org/bin/linux/ubuntu jammy-cran40/ InRelease
[3,632 B]
Get:5 http://archive.ubuntu.com/ubuntu jammy-backports InRelease [127 kB]
Get:6 https://storage.googleapis.com/tensorflow-serving-apt stable InRelease
Get:7 https://r2u.stat.illinois.edu/ubuntu jammy InRelease [6,555 B]
Get:8 http://security.ubuntu.com/ubuntu jammy-security/restricted amd64 Packages
Get:9 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy InRelease
[18.1 kB]
Get:10 http://security.ubuntu.com/ubuntu jammy-security/main amd64 Packages
[3,159 \text{ kB}]
Hit:11 https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu jammy
Get:12 http://security.ubuntu.com/ubuntu jammy-security/universe amd64 Packages
[1.268 kB]
Get:13
https://developer.download.nvidia.com/compute/cuda/repos/ubuntu2204/x86_64
InRelease [1,581 B]
Get:14 http://archive.ubuntu.com/ubuntu jammy-updates/main amd64 Packages [3,470
kB]
Hit:15 https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu jammy InRelease
Get:16 http://archive.ubuntu.com/ubuntu jammy-updates/universe amd64 Packages
[1,574 kB]
Get:17 https://storage.googleapis.com/tensorflow-serving-apt stable/tensorflow-
model-server amd64 Packages [342 B]
Get:18 https://r2u.stat.illinois.edu/ubuntu jammy/main all Packages [9,137 kB]
Get:19 https://storage.googleapis.com/tensorflow-serving-apt stable/tensorflow-
model-server-universal amd64 Packages [347 B]
Get:20 https://r2u.stat.illinois.edu/ubuntu jammy/main amd64 Packages [2,765 kB]
Get:21 https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu jammy/main amd64
Packages [32.9 kB]
https://developer.download.nvidia.com/compute/cuda/repos/ubuntu2204/x86_64
Packages [1,851 kB]
Fetched 28.6 MB in 4s (6,718 \text{ kB/s})
Reading package lists...
Building dependency tree...
Reading state information...
39 packages can be upgraded. Run 'apt list --upgradable' to see them.
```

W: https://storage.googleapis.com/tensorflow-serving-

```
apt/dists/stable/InRelease: Key is stored in legacy trusted.gpg keyring
(/etc/apt/trusted.gpg), see the DEPRECATION section in apt-key(8) for
details.
W: Skipping acquire of configured file 'main/source/Sources' as
repository 'https://r2u.stat.illinois.edu/ubuntu jammy InRelease' does not seem
to provide it (sources.list entry misspelt?)
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
The following NEW packages will be installed:
  tensorflow-model-server
0 upgraded, 1 newly installed, 0 to remove and 39 not upgraded.
Need to get 649 MB of archives.
After this operation, 0 B of additional disk space will be used.
Get:1 https://storage.googleapis.com/tensorflow-serving-apt stable/tensorflow-
model-server amd64 tensorflow-model-server all 2.19.0 [649 MB]
Fetched 649 MB in 13s (50.5 MB/s)
Selecting previously unselected package tensorflow-model-server.
(Reading database ... 126284 files and directories currently installed.)
Preparing to unpack .../tensorflow-model-server 2.19.0 all.deb ...
Unpacking tensorflow-model-server (2.19.0) ...
Setting up tensorflow-model-server (2.19.0) ...
                         644.9/644.9 MB
3.0 MB/s eta 0:00:00
                         4.7/4.7 MB
86.1 MB/s eta 0:00:00
                         5.5/5.5 MB
91.9 MB/s eta 0:00:00
ERROR: pip's dependency resolver does not currently take into account
all the packages that are installed. This behaviour is the source of the
following dependency conflicts.
tensorflow-text 2.18.1 requires tensorflow<2.19,>=2.18.0, but you have
tensorflow 2.19.0 which is incompatible.
tensorflow-decision-forests 1.11.0 requires tensorflow==2.18.0, but you have
tensorflow 2.19.0 which is incompatible.
tf-keras 2.18.0 requires tensorflow<2.19,>=2.18, but you have tensorflow 2.19.0
which is incompatible.
```

Verificam ca portul 8501 sa nu fie blocat de alt si serviciu si omoram procesul daca da

```
pkill -f tensorflow_model_server
```

Urmatoarele 2 celule pornesc serverul pentru TenserFlow

```
import os
os.environ["MODEL_DIR"] = "/content/my_model"
```

```
%%bash --bg
nohup tensorflow_model_server \
    --port=8500 \
    --rest_api_port=8501 \
    --model_name=my_model \
    --model_base_path="${MODEL_DIR}" >server.log 2>&1
```

Asteptam 12 secunde pentru a verifica daca serverul este pornit

```
import time
time.sleep(12)
```

Celula pentru debug in caz ca nu porneste serverul

```
!cat server.log | tail -n 30
```

```
I0000 00:00:1753300963.426565 4095 mlir_graph_optimization_pass.cc:425] MLIR
V1 optimization pass is not enabled
I0000 00:00:1753300963.971040 4095 loader_harness.cc:105] Successfully loaded servable version {name: my_model version: 1}
[warn] getaddrinfo: address family for nodename not supported
[evhttp_server.cc : 261] NET_LOG: Entering the event loop ...

import time
time.sleep(2)
```

Trimitem un request catre server pentru a verifica daca modelul functioneza corect

```
import json
import numpy as np
import requests
# Extrag o instanță de test
sample = X_test_scaled[0].reshape(1, -1)
# Construiesc payload-ul JSON
data = json.dumps({
    "signature_name": "serving_default",
    "instances": sample.tolist()
})
# Trimit requestul către REST API
url = "http://localhost:8501/v1/models/my_model:predict"
headers = {"Content-Type": "application/json"}
response = requests.post(url, data=data, headers=headers)
# Verific rezultat
print("Răspuns complet:", response.json())
print("Clasa prezisă:", np.argmax(response.json()["predictions"][0]))
```

Răspuns complet: {'predictions': [[0.650884271, 0.0919766, 0.257139176]]} Clasa prezisă: 0

10.4.3 Creeam un serviciu de predictie cu Vertex AI

Ne autentificam in google colab sau kaggle

```
project_id = "hopeful-sound-466815-c9" ##### CHANGE THIS TO YOUR PROJECT ID_
    #####

if "google.colab" in sys.modules:
    from google.colab import auth
```

```
auth.authenticate_user()
elif "kaggle_secrets" in sys.modules:
    from kaggle_secrets import UserSecretsClient
    UserSecretsClient().set_gcloud_credentials(project=project_id)
else:
    os.environ["GOOGLE_APPLICATION_CREDENTIALS"] = "my_service_account_key.json"
```

Creeam un bucket nou pentru a face deploy

```
from google.cloud import storage

bucket_name = "bucket_tema2_ia" ##### CHANGE THIS TO A UNIQUE BUCKET NAME #####
location = "us-central1"

storage_client = storage.Client(project=project_id)
# bucket = storage_client.create_bucket(bucket_name, location=location) # to_
create a bucket

bucket = storage_client.bucket(bucket_name) # to reuse a bucket instead
```

```
def upload_directory(bucket, dirpath):
    dirpath = Path(dirpath)
    for filepath in dirpath.glob("**/*"):
        if filepath.is_file():
            blob = bucket.blob(filepath.relative_to(dirpath.parent).as_posix())
            blob.upload_from_filename(filepath)
upload_directory(bucket, "my_model")
```

Initializam server-ul si facem upload la model

```
from google.cloud import aiplatform

server_image = "gcr.io/cloud-aiplatform/prediction/tf2-gpu.2-8:latest"

aiplatform.init(project=project_id, location=location)

# my_model = aiplatform.Model.upload(
# display_name="my_model",
# artifact_uri=f"gs://{bucket_name}/my_model/1",
# serving_container_image_uri=server_image,
# )
```

ATENTIE: Aceasta celula poate avea o durata destul de lunga

Creeam endpoint-ul pentru deploy si il facem

```
# endpoint = aiplatform.Endpoint.create(display_name="my-endpoint")
#
```

Pentru a nu face un nou deploy instantiem deja pe cel pe care il avem

Ordinea celor 3 clase prezise

```
print(le.classes_)
```

```
['high' 'low' 'medium']
```

Folosim testul de la TF pentru a nu avea redundante intre cele 2 metode folosite si vedem probabilitatile

```
print(X_test_scaled[0].reshape(1, -1))
```

```
X_new = X_test_scaled[0].reshape(1, -1)
response = endpoint.predict(instances=X_new.tolist())
```

```
import numpy as np
np.round(response.predictions, 2)
```

```
array([[0.51, 0.11, 0.37]])
```

Obtiem un JSON pentru al folosi in GUI din Google Cloud pentru a testa endpoint-ul

```
import json
sample_instance = X_test_scaled[0].tolist()
print(json.dumps({"instances": [sample_instance]}))
```

```
{"instances": [[-0.3987128717439683, 0.8374712549868658, -0.03871917272651985, -0.5086325129902037, -0.4159167328255186, -0.7022506312261778, -1.0707108246299823, -0.8632764803393801, -0.10500619614502475, -0.9702195123409598, 0.49859670688270824]]}
```

Acest cod se ruleaza puntru a inchide endpoint-ul

```
# endpoint.undeploy_all() # undeploy all models from the endpoint
# endpoint.delete()
```

11 Bibliografie

- RidgeClassifier scikit-learn 1.7.0 documentation
- ADASYN Version 0.13.0
- GridSearchCV scikit-learn 1.7.0 documentation
- RandomForestClassifier scikit-learn 1.7.0 documentation
- GradientBoostingClassifier scikit-learn 1.7.0 documentation
- Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow, Aurélien Geron
- GeeksforGeeks Machine Learning and Deep Learning Tutorials
 - https://www.geeksforgeeks.org/machine-learning/
 - https://www.geeksforgeeks.org/deep-learning-tutorial/
- Towards Data Science Class imbalance handling with ADASYN, SMOTE, etc.
 - https://towardsdatascience.com
- Scikit-learn documentation https://scikit-learn.org/stable/documentation.html
- TensorFlow & Keras documentation https://www.tensorflow.org & https://keras.io
- XGBoost documentation https://xgboost.readthedocs.io/
- Vertex AI (Google Cloud) documentation https://cloud.google.com/vertex-ai/docs
- Google AI Platform Python SDK https://cloud.google.com/python/docs/reference/aiplatform/latest
- TensorFlow Serving https://www.tensorflow.org/tfx/guide/serving

12 Contribuții

- Toma Sabin-Sebastian:
 - A realizat preprocesarea completă a datelor (normalizare, encoding, împărțire în train/val/test).
 - A construit și evaluat modele de bază (RidgeClassifier, XGBoost, MLP).
 - A implementat metricele de performanță (accuracy, F1, MCC, ROC AUC) și vizualizările aferente.
- Scutariu Eduard:
 - A optimizat rețeaua neuronală: experimentare cu funcții de activare, dropout, optimizatori (Adam, SGD, NAG etc.).
 - A aplicat tehnica ADASYN pentru echilibrarea datelor și a interpretat impactul asupra performantei modelului.
 - A documentat comparațiile între modelele optimizate și neoptimizate.
- Liță Gabriel-Laurențiu:
 - A realizat exportul modelului antrenat pentru TensorFlow Serving.
 - A implementat și testat local deploy-ul cu TensorFlow Serving și remote pe Google Vertex AI.
 - A pregătit JSON-urile de test și interpretarea predicțiilor din endpoint-ul GCP.